

Analyse de l'Absentéisme au Travail

Année Universitaire 2025-2026

6 AVRIL 2026 – 12 JUIN 2026

Université Alexandru IOAN Cuza
Hélène Guertin
Mr Danut Jemna
Mr Abdellah Qanari



FEAA
FACULTATEA DE ECONOMIE
ȘI ADMINISTRAREA AFACERILOR

RÉSUMÉ DES MISSIONS DE STAGE

Pour mener à bien ce projet sur l'absentéisme au travail, mon travail s'est découpé en quatre étapes simples :

1. **Comprendre le sujet** : Avant de toucher aux chiffres, j'ai étudié le fonctionnement de l'enquête européenne (EHIS 3). J'ai aussi lu des études existantes pour savoir quels critères (comme l'âge, le métier ou la santé) influencent habituellement les arrêts maladie.
2. **Trier et nettoyer les données** : La base de données de départ était géante et illisible. Sur le logiciel RStudio, j'ai fait du tri pour ne garder que les personnes qui ont un emploi (faisant passer le fichier de 14 192 à 6 902 lignes). J'ai aussi renommé les catégories et regroupé les réponses pour que le fichier devienne propre et facile à utiliser (par exemple, en simplifiant la liste des métiers).
3. **Créer un tableau de bord visuel** : Pour rendre ces chiffres parlants, j'ai créé une application web avec des graphiques interactifs. En un coup d'œil, ce tableau de bord permet de voir et de comprendre comment les absences évoluent selon le profil des gens (les femmes, les jeunes, les sportifs, etc.).
4. **Calculer les véritables causes (le modèle statistique)** : Enfin, j'ai construit un modèle mathématique (une régression logistique). Son but était de découvrir quels facteurs provoquent vraiment les absences en éliminant le hasard. Cela m'a permis de faire un classement précis des risques principaux, comme l'hospitalisation ou le fait de renoncer à se soigner.

SUMMARY OF INTERNSHIP MISSIONS

To successfully complete this project on workplace absenteeism, my work was divided into four simple steps:

1. ***Understanding the topic***: Before diving into the numbers, I studied how the European health survey (EHIS 3) works. I also read existing studies to understand which criteria (such as age, occupation, or health status) usually influence sick leave.
2. ***Sorting and cleaning data***: The initial database was huge and unreadable. Using RStudio software, I filtered the data to keep only employed people, bringing the file down from 14,192 to 6902 rows. I also renamed the categories and grouped answers to make the file clean and easy to use, for example, by simplifying the long list of occupations.
3. ***Creating a visual dashboard***: To make these numbers meaningful, I built a web application with interactive charts. In just a glance, this dashboard allows users to see and understand how absenteeism changes depending on people's profiles, such as women, young people, or athletes.
4. ***Finding the true causes (the statistical model)***: Finally, I built a mathematical model using logistic regression. Its goal was to find out which factors truly cause absences by eliminating chance. This allowed me to create an accurate ranking of the main risks, such as recent hospitalization or skipping medical care due to costs or delays.

AVANT-PROPOS

Étant étudiante de deuxième année de BUT Science des Données, j'ai eu l'occasion de découvrir un domaine qui fait le lien entre la programmation et l'analyse de données. Au fil de mon parcours, j'ai pu acquérir des bases techniques en travaillant sur des données et en utilisant différents outils informatiques.

Je me suis orientée vers ce domaine car il m'intéresse de voir comment les données peuvent servir à éclairer des décisions et à répondre à des problématiques concrètes. Dans ce cadre, j'ai réalisé un stage dans un laboratoire de recherche en Roumanie, autour de données européennes, ce qui a marqué une étape importante dans mon parcours.

Cette expérience m'a permis d'appliquer mes connaissances dans un contexte réel, de découvrir de nouvelles approches d'analyse et d'évoluer dans un environnement international. Elle m'a aidée à mieux comprendre les enjeux du domaine.

Remerciements :

Avant de commencer ce rapport, je tiens à remercier toutes les personnes qui m'ont aidé et accompagné pendant ce stage.

Je remercie d'abord l'Université Alexandru Ioan Cuza de Iași pour son accueil, ainsi qu'au Laboratoire d'Économie et Statistiques. Un grand merci à monsieur JEMNA, pour sa confiance, sa disponibilité, sa patience et ses encouragements constants. Ses conseils m'ont beaucoup aidé à progresser, notamment sur RStudio pour créer mon modèle de régression logistique. Ce séjour à Iași a été une très belle expérience humaine et professionnelle.

Je tiens à remercier tout particulièrement mes professeurs. Merci pour leur soutien dans mes études, mais surtout pour leur aide précieuse et leur grande réactivité dans l'aide pour toute la partie administrative, ce qui a grandement facilité l'organisation de ce stage à l'étranger.

Je remercie également la Région pour sa confiance et pour l'attribution de la bourse, qui m'a permis de financer et de réaliser sereinement ce projet à l'international.

SOMMAIRE

Résumé des missions.....	2
Avant-propos et remerciement.....	4
Introduction.....	6

1. Contexte et Présentation de la Structure d'Accueil

1.1 Le contexte général de la ville de Iași.....	7
1.2 L'Université Alexandru Ioan Cuza de Iași : une institution historique majeure.....	7
1.3 Organisation générale de l'Université Alexandru Ioan Cuza.....	8
1.4 Le laboratoire d'accueil : économie et statistiques.....	8
1.5 Missions et axes de recherche du laboratoire.....	8

2. EHIS 3 pour mesurer l'absentéisme au travail via la variable AW1

2.1 L'étude EHIS 3 : Enquête Européenne sur la Santé.....	9
2.2 Une méthode de collecte au service de l'analyse.....	9
2.3 Échantillonnage et structure de l'échantillon.....	10
2.4 Un questionnaire structuré pour une analyse pertinente.....	10
2.5 Focus sur la mise en œuvre de l'EHIS en France.....	11
2.6 L'absentéisme au travail : un indicateur clé de l'état de santé.....	11
2.7 Comprendre les déterminants de l'absentéisme : analyse des études existantes.....	12

3. Exploration et analyse des déterminants de l'absentéisme au travail à partir des données EHIS 3

3.1 Sélection des variables afin d'analyser AW1.....	13
3.2 Traitement et nettoyage des données (RStudio).....	16
3.3 Recodification finale des variables analytiques.....	19
3.4 Architecture et structure de l'outil de datavisualisation.....	22
3.5 Analyse des résultats : les variables clés de l'absentéisme selon la datavisualisation.....	24
3.6 Création du modèle de régression logistique et résultats.....	25

4. Retour d'expérience et bilan du projet

4.1 Difficultés rencontrées.....	29
4.2 Compétences Techniques et Analytiques Acquisées.....	29
4.3 Développement Personnel et Adaptation Culturelle.....	30
4.4 Conclusion.....	30

Annexe.....	31
-------------	----

INTRODUCTION

L'analyse de données occupe aujourd'hui une place majeure dans la compréhension de problématiques complexes, particulièrement à la croisée du monde du travail et de la santé publique. Parmi ces enjeux, l'absentéisme au travail s'impose comme un indicateur clé pour évaluer à la fois l'état de santé d'une population et son impact sur les organisations. C'est pour répondre à ce besoin de compréhension et d'identification des facteurs de risque que s'est déroulé mon stage du 6 avril au 12 juin 2026 au sein de l'Université Alexandru Ioan Cuza à Iași, en Roumanie. Intégrée au laboratoire de recherche en économie et statistiques de la Faculté d'Économie et d'Administration des Affaires (FEAA), j'ai participé activement à une étude statistique approfondie sur les déterminants de l'absentéisme en France, en exploitant les données de la grande enquête européenne EHIS 3 et sa variable cible AW1.

Pour mener à bien ce projet, mon travail a suivi une progression logique et rigoureuse au travers de plusieurs missions successives. Ma toute première tâche a consisté à me renseigner en profondeur sur l'enquête EHIS 3 afin de bien comprendre le sujet, ses enjeux et ses subtilités méthodologiques. Ensuite, en m'appuyant sur la littérature scientifique et les études existantes, j'ai pu choisir, nettoyer et recodifier les variables les plus pertinentes sous RStudio. Une fois cette base de données prête, j'ai développé un outil de datavisualisation interactif pour explorer graphiquement les données et comprendre les mouvements, les écarts et les grandes tendances de l'absentéisme. Enfin, la dernière étape de mes missions a été de construire le modèle statistique de régression logistique afin d'isoler et de hiérarchiser les véritables leviers qui influencent le risque d'absence.

Ce rapport s'articule ainsi en trois grandes parties pour retracer le déroulement de cette expérience. La première partie est dédiée au contexte général de la ville de Iași et à la présentation de mon université et de mon laboratoire d'accueil. La deuxième section aborde les aspects théoriques et méthodologiques de l'enquête EHIS 3 pour bien cibler l'absentéisme au travail. Enfin, la troisième partie retrace toute ma démarche technique d'exploration des données, depuis la préparation et le nettoyage sur RStudio jusqu'à la présentation finale des résultats de ma datavisualisation et de ma modélisation statistique

Partie I : Présentation de la structure d'accueil

1. Le contexte général de la ville de Iași

Iași, située dans le nord-est de la Roumanie, est l'une des plus anciennes et importantes villes du pays. Ancienne capitale de la Moldavie entre 1564 et 1859, elle a aussi été capitale de la Roumanie durant une partie de la Première Guerre mondiale. Aujourd'hui, elle compte environ 271 000 habitants et plus de 420 000 dans son aire métropolitaine, ce qui en fait la deuxième plus grande ville du pays après Bucarest. Iași est également un important centre culturel, religieux et économique, mais surtout un grand pôle universitaire. Elle accueille plus de 57 000 étudiants, notamment à l'Université Alexandru Ioan Cuza, fondée en 1860. Grâce à ses universités, ses instituts de recherche et le développement du secteur informatique, la ville connaît aujourd'hui une forte dynamique de croissance.



Carte de la Roumanie



2. L'Université Alexandru Ioan Cuza de Iași : une institution historique majeure

Fondée en 1860, l'Université Alexandru Ioan Cuza est la plus ancienne université de Roumanie. Elle porte le nom du prince Alexandru Ioan Cuza, qui a réalisé l'union des principautés de Moldavie et de Valachie en 1859, un événement clé dans la formation de l'État roumain moderne.



Photo de l'université

Grâce à son histoire, à la diversité de ses formations et à son engagement dans la recherche, l'université occupe une place importante dans l'enseignement supérieur roumain. Elle compte aujourd'hui environ 24 000 étudiants et propose un large éventail de programmes dans divers domaines académiques, ce qui fait de l'UAIC un acteur majeur du développement académique du pays.

3. Organisation générale de l'Université Alexandru Ioan Cuza

L'Université Alexandru Ioan Cuza est composée de 15 facultés couvrant de nombreux domaines, tels que les sciences humaines, les sciences sociales, les sciences exactes et l'informatique. Chaque faculté est organisée en plusieurs départements chargés de coordonner les programmes d'enseignement et les activités de recherche.

Cette structure favorise la coopération entre les disciplines et contribue au développement de projets académiques diversifiés. L'université comprend également plusieurs centres de recherche, écoles doctorales et instituts spécialisés, qui participent au développement scientifique et à l'innovation.

4. Le laboratoire d'accueil : économie et statistiques

Lors de mon stage j'ai pu intégrer le laboratoire de recherche en économie et statistiques de l'UAIC, rattaché à la faculté d'économie et d'administration des affaires. Ce laboratoire mène des travaux axés sur l'utilisation d'outils statistiques et de méthodes économétriques afin d'analyser différentes problématiques économiques et sociales.

Les membres de l'équipe participent à des projets de recherche variés, portant notamment sur l'étude des dynamiques économiques, l'analyse de données sociales ou encore l'évaluation de politiques publiques. Cet environnement de recherche m'a permis de découvrir concrètement l'application des méthodes d'analyse de données dans des contextes réels.

5. Missions et axes de recherche du laboratoire

Le laboratoire a pour mission de développer des méthodes d'analyse appliquées aux données économiques et sociales. Les travaux menés visent notamment à élaborer des modèles statistiques et économétriques afin de mieux comprendre certaines problématiques et d'apporter des éléments d'aide à la décision pour les acteurs publics et privés. Par ailleurs, les activités du laboratoire contribuent également à la recherche académique à travers la participation à des conférences et la publication de travaux scientifiques.

Au cours de mon stage, j'ai eu l'opportunité de participer à une étude portant sur l'analyse des arrêts maladie à partir de données européennes. Cette expérience m'a permis de mobiliser mes compétences en statistique et en analyse de données afin d'identifier des tendances, d'explorer les informations disponibles et de contribuer à l'interprétation des résultats obtenus.

2.1. L'étude EHIS 3 : Enquête Européenne sur la Santé

L'European Health Interview Survey (EHIS) est une enquête européenne de grande ampleur menée auprès des personnes âgées de 15 ans ou plus vivant dans des ménages privés. Elle a pour objectif de collecter des informations comparables entre les pays européens concernant la santé des populations, leurs conditions de vie et leur relation avec le système de soins. Ces données permettent d'analyser différentes problématiques de santé publique à l'échelle européenne.

L'enquête regroupe plusieurs thématiques, notamment l'état de santé des individus, leurs habitudes de vie, leur recours aux soins ainsi que leurs caractéristiques socio-économiques. Dans le cadre de mon stage, je me suis particulièrement concentrée sur les variables liées aux arrêts de travail, en lien avec l'état de santé et la situation professionnelle des individus. Ces informations permettent d'étudier les facteurs associés aux absences pour raison de santé et d'observer les différences entre pays.

La troisième vague de l'enquête, EHIS 3, lancée en 2019, couvre l'ensemble des pays de l'Union européenne ainsi que certains pays partenaires. Les données sont mises à disposition sous forme de micro données anonymisées afin de garantir la confidentialité des participants. Certaines variables sont toutefois regroupées en catégories, comme l'âge ou les revenus, afin de préserver l'anonymat.

2.2. Une méthode de collecte au service de l'analyse

L'European Health Interview Survey (EHIS 3) repose sur une collecte de données harmonisée à l'échelle européenne, encadrée par Eurostat. Les informations sont recueillies à l'aide de questionnaires standardisés, administrés soit par un enquêteur (en face à face ou par téléphone), soit directement par les individus (en ligne ou par courrier). Dans la pratique, de nombreux pays utilisent une approche mixte combinant plusieurs modes de collecte afin d'améliorer le taux de réponse et la qualité des données.

- **CAPI** (Computer-Assisted Personal Interviewing) pour les entretiens en face à face,
- **CATI** (Computer-Assisted Telephone Interviewing) pour les enquêtes téléphoniques,
- **CAWI** (Computer-Assisted Web Interviewing) pour les questionnaires en ligne.

En France, en raison de l'épidémie de COVID-19, les enquêtes réalisées en mars et avril 2020 ont été menées uniquement par téléphone (CATI). Par ailleurs, des mesures de contrôle de qualité ont été mises en place par l'Institut National de la Statistique (INS) afin de garantir la fiabilité des données collectées. Par ailleurs, le mode de collecte peut influencer les réponses, ce qui justifie la prise en compte de cette information dans l'analyse des données.

2.3. Échantillonnage et structure de l'échantillon

L'EHIS utilise un échantillonnage probabiliste, ce qui signifie que chaque personne appartenant à la population cible (les individus âgés de 15 ans et plus vivant en logement ordinaire) a une probabilité connue d'être sélectionnée. Les participants sont choisis à partir de sources fiables, telles que des registres de population ou des bases de données administratives, afin de garantir une bonne représentation de la population étudiée.

Le tirage de l'échantillon suit généralement plusieurs étapes. D'abord, la population est divisée en groupes (par exemple selon l'âge, le sexe ou la région) afin de mieux représenter sa diversité : c'est ce qu'on appelle la stratification. Ensuite, la sélection se fait progressivement, en choisissant des zones géographiques, puis des ménages, et enfin des individus. En général, une seule personne est sélectionnée par ménage, ce qui permet d'éviter des biais liés au fait que les membres d'un même foyer ont souvent des caractéristiques similaires.

La taille de l'échantillon est définie pour garantir des résultats suffisamment précis.

Elle dépend notamment de la taille de la population du pays. Par ailleurs, certains groupes peuvent être volontairement surreprésentés pour obtenir des analyses plus fiables les concernant. Enfin, des pondérations sont appliquées aux données afin de corriger les déséquilibres (comme la non-réponse) et de s'assurer que les résultats reflètent bien l'ensemble de la population.

2.4. Un questionnaire structuré pour une analyse pertinente

Le questionnaire de l'EHIS est standardisé au niveau européen et structuré en plusieurs grandes thématiques visant à couvrir de manière complète l'état de santé et les conditions de vie des individus.

Il comprend tout d'abord des **variables techniques**, utilisées pour le suivi de la collecte (mode d'enquête, qualité des données, pondérations), ainsi que des **variables socio-démographiques** permettant de décrire le profil des répondants (âge, sexe, niveau d'éducation, situation professionnelle, composition du ménage).

Une partie centrale est consacrée à la **santé**, incluant notamment :

- L'état de santé perçu et les maladies chroniques,
- Les limitations fonctionnelles et l'autonomie dans les activités quotidiennes,
- La santé mentale et la douleur,
- Ainsi que l'impact de la santé sur la vie professionnelle, notamment l'absence au travail.

Le questionnaire aborde également le **recours aux soins**, en s'intéressant aux hospitalisations, aux consultations médicales, à la consommation de médicaments, aux actions de prévention, ainsi qu'aux éventuels besoins de soins non satisfaits.

Enfin, une dernière partie concerne les **déterminants de la santé**, comme les comportements individuels (activité physique, alimentation, tabac, alcool), mais aussi certains facteurs sociaux tels que le soutien social ou l'aide apportée à des proches.

Le questionnaire repose sur une logique de filtrage : certaines questions ne sont posées qu'aux individus concernés, en fonction de leurs réponses précédentes. Cela permet d'adapter le parcours de réponse et d'éviter des questions inutiles.

Cette organisation améliore la qualité et la cohérence des données tout en limitant la charge pour les répondants. Associée à un échantillonnage rigoureux et à l'application de pondérations, elle permet de produire des données fiables et comparables, essentielles pour analyser les liens entre santé, conditions de vie et activité professionnelle.

2.5. Focus sur la mise en œuvre de l'EHIS en France

En France, l'European Health Interview Survey (EHIS 3) est mise en œuvre par la DREES et l'IRDES, avec l'appui de l'INSEE pour les aspects d'échantillonnage. L'enquête repose sur un échantillon d'environ 20 000 individus, représentatif de la population vivant en logement ordinaire, ce qui permet de produire des résultats fiables à l'échelle nationale.

L'échantillon est construit à partir de bases administratives de l'INSEE, garantissant une bonne couverture de la population et une sélection rigoureuse des individus. Le questionnaire européen standard est utilisé, afin de conserver la comparabilité avec les autres pays, tout en intégrant certains modules spécifiques à la France, notamment sur la complémentaire santé et l'organisation du système de soins.

Une particularité importante du dispositif français est la possibilité d'enrichir les données de l'enquête par un appariement avec les bases de l'Assurance maladie. Cela permet de compléter les réponses déclaratives par des données objectives sur la consommation de soins, renforçant ainsi la qualité et la précision des analyses.

2.6. L'absentéisme au travail : un indicateur clé de l'état de santé

Dans la troisième vague de l'European Health Interview Survey (EHIS), la variable **AW1** indique si une personne a été absente de son travail au cours d'une période de référence, généralement les douze derniers mois. Cette variable binaire sert de filtre pour repérer les individus concernés.

Les variables associées, renseignées uniquement en cas de réponse positive, apportent des précisions sur l'absence, notamment sa durée ou ses causes, souvent liées à l'état de santé. Cette structure conditionnelle permet de cibler l'analyse et d'évaluer l'impact des problèmes de santé sur l'activité professionnelle.

2.7. Comprendre les déterminants de l'absentéisme : analyse des études existantes

L'absentéisme au travail correspond au fait pour un individu de s'absenter de son activité professionnelle, généralement pour des raisons de santé. Dans l'enquête EHIS 3, il est mesuré à partir de la variable AW1, qui identifie les personnes ayant été absentes du travail en raison d'un problème de santé. Ainsi, est considéré comme absentéiste tout individu déclarant une absence liée à sa santé.

L'objectif est d'identifier les facteurs associés à cet absentéisme en s'appuyant sur l'enquête EHIS et sur la documentation existante. L'article "*European Health Interview Survey (EHIS) : overview and methodological aspects*" (2022) souligne que l'EHIS permet d'analyser de manière harmonisée, à l'échelle européenne, les liens entre état de santé, recours aux soins et caractéristiques socio-économiques (EHIS, 2022). Cette richesse permet notamment d'étudier des phénomènes comme l'absentéisme.

L'EHIS permet d'étudier ce phénomène grâce à plusieurs catégories de données : les variables **socio-démographiques** (âge, sexe, niveau d'éducation), les variables liées à l'**état de santé** (santé perçue, maladies chroniques, limitations d'activité), les **déterminants de santé** (tabac, alcool, activité physique, IMC) ainsi que les données liées au **recours aux soins** (EHIS, 2022).

Plusieurs études montrent que certains facteurs influencent fortement l'absentéisme. L'âge (AGE) est souvent associé à une augmentation des absences, car les personnes plus âgées sont davantage touchées par les maladies chroniques et les limitations physiques (WHO, 2019). Le sexe (SEX) joue également un rôle : les femmes déclarent généralement plus d'absences, notamment à cause des conditions de travail et des responsabilités familiales (OECD, 2022). Le niveau d'éducation influence aussi l'absentéisme, les individus les moins diplômés étant souvent exposés à des emplois plus pénibles physiquement (Vuorio et al., 2019).

Les variables de santé apparaissent cependant comme les plus explicatives. Une mauvaise **santé perçue** (HS1) augmente fortement la probabilité d'être absent, car elle reflète directement les difficultés physiques et psychologiques ressenties par l'individu (Bacigalupe et al., 2022). La présence de **maladies chroniques** (HS2) est aussi fortement liée à l'absentéisme : plusieurs études montrent que les personnes souffrant de plusieurs maladies chroniques présentent davantage d'arrêts de travail (Vuorio et al., 2019). Les **limitations d'activité** (GALI) constituent également un facteur important car elles réduisent la capacité à exercer une activité professionnelle normale (Eurostat, 2020).

Enfin, plusieurs comportements de santé influencent indirectement l'absentéisme. Le **tabagisme**, l'**obésité**, la consommation d'alcool ou un faible niveau d'activité physique augmentent les risques de mauvaise santé et donc d'absence au travail (Roos et al., 2017 ; Lund et al., 2019). Certaines études montrent également que le stress professionnel et de mauvaises conditions de travail augmentent les absences et les pertes de productivité (Brunner et al., 2019).

PARTIE III : Sélection, exploration et analyse de l'absentéisme au travail à partir des données EHIS 3

3.1. Sélection des variables afin d'analyser AW1

Présentation synthétique des variables que j'ai sélectionnées pour analyser les facteurs associés à l'absentéisme des individus, en prenant en compte les caractéristiques socio-démographiques, l'état de santé, les déterminants de santé ainsi que le recours aux soins.

TABLEAU D'ENCODAGE DE LA BASE DE DONNÉES

Enquête Européenne sur la Santé (EHIS - Vague 3) — Spécifications des Variables

1. VARIABLES SOCIO-DÉMOGRAPHIQUES DE BASE ET PROFILS PROFESSIONNELS

Variable EHIS	Sens de la variable (Ce qu'elle évalue...)	Modalités de réponse et codes exacts	Pertinence pour analyser l'absentéisme
SEX	Évalue le genre / sexe biologique de l'enquêté.	1 = Homme 2 = Femme	Analyse des écarts hommes/femmes liés aux charges familiales ou pathologies spécifiques.
AGE	Évalue l'âge exact atteint par l'individu.	Valeur numérique continue (Âge en années révolues au moment de l'entretien).	Indicateur clé de l'effet du vieillissement (maladies chroniques, temps de récupération).
HATLEVEL	Évalue le niveau d'études ou d'instruction le plus élevé atteint par la personne.	Basé sur la classification ISCED-2011, codes ISCED_A : 0 : No formal education or below ISCED 1 1 : ISCED 1 Primary education 2 : ISCED 2 Lower secondary education 3 : ISCED 3 Upper secondary education 4 : ISCED 4 Post-secondary but non-tertiary education 5 : ISCED 5 Short-cycle tertiary education; 6 : ISCED 6 Bachelor's or equivalent level; 7 : ISCED 7 Master's or equivalent level; 8 : ISCED 8 Doctoral or equivalent level -1 : Not stated	Mesure des inégalités sociales de santé (un faible niveau est corrélé à des postes plus pénibles).
JOBISCO	Évalue la catégorie socio-professionnelle fine selon la nomenclature internationale ISCO-08.	1 : Directeurs, cadres de direction et gérants 2 : Professions intellectuelles et scientifiques 3 : Professions intermédiaires 4 : Employés de bureau 5 : Personnels des services directs aux particuliers et commerçants 6 : Agriculteurs et ouvriers qualifiés de l'agriculture, de la sylviculture et de la pêche 7 : Artisans et ouvriers des métiers qualifiés de l'industrie et de l'artisanat 8 : Conducteurs d'installations et de machines, et ouvriers de l'assemblage 9 : Professions élémentaires (manœuvres, nettoyeurs) 0 : Militaires -1 : Non déclaré -2 : Non applicable (Uniquement posé si la personne est en emploi)	Évaluation des risques professionnels par poste (risques physiques vs psychosociaux).

2. VARIABLES LIÉES À L'ÉTAT DE SANTÉ (STATUT DE SANTÉ)

Variable EHIS	Sens de la variable (Ce qu'elle évalue...)	Modalités de réponse et codes exacts	Pertinence pour analyser l'absentéisme
HS1	Évalue l'état de santé général de manière subjective par l'enquête.	1 : Très bonne 2 : Bonne 3 : Assez bonne / Moyenne 4 : Mauvaise 5 : Très mauvaise	Indicateur prédictif global (un mauvais état perçu est le principal déclencheur d'arrêt).
CD1a	Évalue la présence d'un asthme diagnostiqué chez l'individu.	1 = Oui 2 = Non -1 = Non déclaré	Analyse des absences liées aux crises aiguës ou à l'inadaptation de l'environnement de travail.
CD1c	Évalue la présence de maux de dos chroniques ou de pathologies lombaires.	1 = Oui 2 = Non -1 = Non déclaré	Mesure de l'impact des TMS, cause première des arrêts physiques répétés ou de longue durée.
CD1I	Évalue la survenue ou présence d'une dépression chronique.	1 = Oui 2 = Non -1 = Non déclaré	Évaluation de la santé mentale et des RPS (génère des arrêts statistiquement plus longs).

3. DÉTERMINANTS DE SANTÉ (HABITUDES DE VIE ET CONTRAINTES)

Variable EHIS	Sens de la variable (Ce qu'elle évalue...)	Modalités de réponse et codes exacts	Pertinence pour analyser l'absentéisme
SK1	Évalue la régularité du statut de fumeur.	1 : Oui, quotidiennement 2 : Oui, occasionnellement 3 : Pas du tout	Corrélation avec les risques respiratoires et cardiovasculaires qui augmentent la morbidité.
SK2 / SK2B	Évalue le volume physique journalier du tabagisme.	Valeur numérique entière comprise entre 1 et 99 (Nombre de cigarettes par jour). <i>Note : Vaut 0 pour les non-fumeurs et occasionnels.</i>	Mesure d'un effet dose-réponse potentiel sur la fréquence ou la durée des arrêts maladie.
AL1	Évalue la récurrence temporelle de la consommation de boissons alcoolisées.	1 : Tous les jours ou presque tous les jours 2 : 5 à 6 jours par semaine 3 : 3 à 4 jours par semaine 4 : 1 à 2 jours par semaine 5 : 2 à 3 jours par mois 6 : Une fois par mois 7 : Moins d'une fois par mois 8 : Pas du tout au cours des 12 derniers mois (ancien consommateur) 9 : Jamais (ou seulement quelques gorgées au cours de la vie)	Analyse des risques de désorganisation (arrêts courts répétés) et d'accidents du travail.
PE1	Évalue l'effort physique fourni et la pénibilité au cours de l'activité professionnelle.	1 : Surtout assis ou debout (faible effort physique) 2 : Marche ou tâches nécessitant un effort physique modéré 3 : Tâches nécessitant un effort physique intense/lourd 4 : Non applicable (Inactifs, personnes sans emploi) -1 : Non déclaré	Lien direct avec l'usure corporelle, la fatigue musculaire et le déclenchement des arrêts.
BM1 / BM2	Évalue la corpulence physique de l'individu via les indicateurs de calcul de l'IMC.	Variables continues pour le calcul de l'IMC (Poids / Taille²): • BM1 : Taille brute en centimètres (cm) • BM2 : Poids brut en kilogrammes (kg)	Analyse de l'impact des risques métaboliques et de l'obésité (vulnérabilité accrue aux TMS).

4. RECOURS AUX SOINS (SOINS DE SANTÉ)

Variable EHIS	Sens de la variable (Ce qu'elle évalue...)	Modalités de réponse et codes exacts	Pertinence pour analyser l'absentéisme
AM2	Évalue le suivi médical général ou spécialisé sur une période de référence.	1 : Il y a moins de 12 mois 2 : Il y a 12 mois ou plus 3 : Jamais	Permet de distinguer la prise en charge préventive d'un indicateur de pathologie active.
HO1	Évalue l'intensité de la prise en charge en milieu hospitalier.	Valeur numérique continue (Nombre exact de nuits passées en hospitalisation sur l'année). <i>Note : Vaut 0 si aucune nuit d'hospitalisation.</i>	Marqueur de chocs de santé aigus, expliquant directement les arrêts de longue durée.
MD1	Évalue l'exposition récente à un traitement médical d'origine thérapeutique.	1 = Oui (Médicaments prescrits consommés durant les 2 dernières semaines) 2 = Non -1 = Non déclaré	Mesure de la présence d'une affection aiguë ou chronique active impactant la capacité de travail.
UN1A	Évalue les freins d'accès aux soins imputables à la logistique du système médical.	1 = Oui (Besoins de soins non satisfaits dus à l'attente) 2 = Non -1 = Non déclaré	Analyse de l'allongement d'un arrêt provoqué par les délais de rendez-vous médicaux.
UN1B	Évalue les entraves géographiques pour l'accès aux infrastructures médicales.	1 = Oui (Besoins de soins non satisfaits dus à la distance/transport) 2 = Non -1 = Non déclaré	Mesure de l'impact des déserts médicaux sur le retard de diagnostic et la durée des arrêts.
UN2	Évalue la barrière ou le renoncement aux soins lié aux contraintes budgétaires personnelles.	1 = Oui (N'a pas pu se le permettre financièrement) 2 = Non (N'en avait pas besoin ou a pu payer) -1 = Non déclaré	Lien entre précarité financière, aggravation de l'état de santé et arrêts de longue durée.
AM1	Évalue la régularité du suivi et de la prévention bucco-dentaire.	1 = Moins de 12 mois 2 = 12 mois ou plus 3 : Jamais -1 = Non déclaré	Marqueur comportemental global de prévention ou indicateur d'urgences douloureuses courtes.

5. VARIABLES D'ABSENTÉISME (ABSENCE DU TRAVAIL)

Variable EHIS	Sens de la variable (Ce qu'elle évalue...)	Modalités de réponse et codes exacts	Pertinence pour analyser l'absentéisme
AW1	Évalue l'incidence / occurrence d'un arrêt de travail récent pour motif de santé propre.	1 = Oui (Absent du travail pour raisons de santé personnelles) 2 = Non -1 = Non déclaré -2 = Non applicable (Inactifs, chômeurs)	Variable cible binaire (Y). Mesure l'incidence brute (probabilité d'avoir au moins un arrêt).
AW2	Évalue le volume temporel global et le cumul annuel des journées d'absence.	Valeur numérique continue comprise entre 1 et 365 (Nombre exact de jours cumulés d'absence). <i>Note : Vaut 0 si est_absent = Non.</i>	Variable d'intensité (continue). Distingue l'absentéisme frictionnel (court) de l'absentéisme lourd (long).

Résumer des sélections :

Les variables sélectionnées pour l'analyse de l'absentéisme ont été regroupées en quatre grandes catégories. Les variables socio-démographiques (SEX, AGE, HATLEVEL, JOBISCO) permettent d'étudier les inégalités sociales, les profils professionnels et les différences d'exposition aux risques. Les variables liées à l'état de santé et à l'absentéisme (AW1, AW2, HS1, CD1a, CD1c, CD1l) mesurent l'incidence, la durée des arrêts de travail ainsi que l'impact des pathologies chroniques ou de la santé perçue. Les déterminants de santé (SK1, SK2, AL1, PE1, BM1/BM2) permettent d'identifier les comportements de vie, la corpulence et la pénibilité physique aux postes associés à l'absentéisme. Enfin, les variables de recours aux soins (AM2, HO1, MD1, UN1A, UN1B, UN2, AM1) évaluent l'accès aux structures médicales, les traitements, les hospitalisations ainsi que l'impact du non-recours ou du renoncement aux soins des individus.

3.2. Traitement et nettoyage des données (RStudio)

Afin d'exploiter les données brutes de l'enquête EHIS et de répondre à notre problématique sur l'absentéisme au travail, un travail rigoureux de nettoyage, de filtrage et de restructuration a été mené sous RStudio à l'aide du package tidyverse (notamment dplyr).

3.2.1. Sélection de la population d'étude et réduction du volume

Le jeu de données initial comprenait un volume important de **14 192 observations** et **151 variables**. Comme vous pouvez le constater les données sont trop volumineuses et incompréhensible a première vue :

PID3	HHID	WGOT	WGT	SPD_SPEAKPROX	REFDATE	INTNETMCSEX	AGE	COUNTRY	REGION	BIRTHPLA	CITIZEN	BIRTHPLA	BIRTHPLA	DEG	URS	HATLEVEL	MANSTAT	FT	PT	JOBSAT	JOBSICO	LOCNAME	PARTNER	MARSTALE	HHNBPFF	HHNBPFF	HYMTYPE	HHNHCOR	HS1	HS2	HS3	CD1A	CD1B			
27373	27373	1231	803	1213	803	1	20911	31	1	25-29	FR	-1	10	10	10	10	1	3	50	-2	-2	-2	-2	-2	2	1	4	0	4	1	2	2	3	2	2	
27375	27375	1568	719	1568	719	1	20909	31	1	18-19	FR	-1	10	10	22	22	1	3	50	-2	-2	-2	-2	-2	1	5	0	4	1	2	2	3	2	2		
27379	27379	1689	166	1689	166	1	20909	31	2	15-17	FR	-1	10	10	10	10	1	2	50	-2	-2	-2	-2	-2	-2	1	3	0	2	2	2	2	3	2	2	
27385	27385	1922	360	1922	360	1	20910	31	2	15-17	FR	-1	10	10	10	10	1	2	50	-2	-2	-2	-2	-2	1	7	0	2	1	2	2	3	2	2		
27393	27393	1450	306	1450	306	1	20910	31	2	28-34	FR	-1	10	10	10	10	1	3	30	-2	-2	-2	-2	-2	1	3	0	6	4	2	2	1	3	1	1	
27396	27396	3120	491	3120	491	1	202001	21	1	14-49	FR	-1	22	22	22	22	1	2	20	-2	-2	-2	-2	-2	2	2	1	0	1	2	5	1	2	2	2	
27401	27401	1436	600	1436	600	1	202001	21	1	55-59	FR	-1	22	22	22	2	2	20	-2	-2	-2	-2	-2	1	2	0	3	2	3	2	3	2	3	2		
27403	27403	1286	540	1286	540	1	20909	31	1	35-39	FR	-1	22	22	22	2	35	30	-2	-2	-2	-2	-2	1	2	0	3	2	2	3	2	3	2	2		
27406	27406	2056	319	2056	319	1	20909	31	1	70-74	FR	-1	10	10	22	2	0	30	-2	-2	-2	-2	-2	2	2	3	1	1	0	1	2	3	1	2	2	
27408	27408	1502	409	1502	409	1	20908	31	2	75-79	FR	-1	10	10	10	10	2	1	30	-2	-2	-2	-2	-2	1	2	2	3	2	2	1	3	2	2		
27409	27409	3565	162	3565	162	1	20909	31	1	14-49	FR	-1	22	22	22	22	2	20	-2	-2	-2	-2	-2	1	4	1	0	1	1	4	2	2	1	2		
27410	27410	1476	672	1476	672	1	20909	31	1	50-54	FR	-1	10	10	10	1	50	70	-2	-2	-2	-2	-2	1	5	0	2	1	1	1	1	2	1	2		
27411	27411	1301	399	1301	399	1	20909	31	1	20-44	FR	-1	10	10	10	10	2	2	20	-2	-2	-2	-2	-2	1	2	5	3	4	1	4	1	1	2	2	
27412	27412	1634	265	1634	265	1	20909	31	1	40-44	FR	-1	22	22	22	22	1	3	10	-1	20	9	2	2	1	2	5	3	4	4	2	2	3	1	2	
27414	27414	1130	546	1130	546	1	20909	21	1	50-54	FR	-1	10	10	10	10	1	0	20	-2	-2	-2	-2	-2	1	4	0	1	1	2	3	3	2	2		
27416	27416	2173	988	2173	988	1	20910	21	1	70-74	FR	-1	10	10	10	10	1	0	30	-2	-2	-2	-2	-2	1	5	0	2	1	6	7	3	7	2	2	
27417	27417	1726	583	1726	583	1	20910	21	1	20-44	FR	-1	10	10	10	10	1	0	30	-2	-2	-2	-2	-2	1	2	2	3	2	4	1	2	2	2		
27423	27423	1881	617	1881	617	1	20909	31	2	30-34	FR	-1	10	10	10	10	2	5	10	1	20	5	7	1	1	2	2	0	3	1	2	2	3	2	2	
27427	27427	1610	131	1610	131	1	20909	31	1	35-39	FR	-1	10	10	10	10	1	35	30	-2	-2	-2	-2	-2	1	5	0	2	1	1	2	3	2	2		
27428	27428	1773	398	1773	398	1	20910	21	1	20-44	FR	-1	10	10	10	10	2	5	10	-2	20	9	6	2	1	1	1	0	1	2	2	1	2	3	2	
27436	27436	1957	647	1957	647	1	20912	21	1	45-49	FR	-1	10	10	10	10	1	0	60	-2	-2	-2	-2	-2	1	2	3	0	1	2	2	3	2	2		
27437	27437	1435	981	1435	981	1	20909	31	2	25-29	FR	-1	10	10	10	10	1	6	10	1	20	2	8	1	1	2	3	1	4	2	2	2	3	2	2	
27439	27439	2048	310	2048	310	1	20909	31	1	20-44	FR	-1	10	10	10	10	1	30	34	-2	-2	-2	-2	-2	1	3	1	0	1	1	2	2	2	2		
27440	27440	4140	124	4140	124	1	20911	21	1	65-69	FR	-1	22	22	22	22	1	0	30	-2	-2	-2	-2	-2	2	4	1	0	1	1	4	1	2	2	2	
27441	27441	1566	193	1566	193	1	20909	31	1	80-84	FR	-1	10	10	10	10	1	1	30	-2	-2	-2	-2	-2	1	2	2	0	3	5	4	1	1	2	2	
27443	27443	2587	231	2587	231	1	20909	31	1	15-17	FR	-1	10	22	22	22	1	50	-2	-2	-2	-2	-2	-2	1	4	1	4	1	1	2	2	3	2		
27527	27527	2530	758	2530	758	1	20910	21	1	55-59	FR	-1	10	10	22	22	1	50	-2	-2	-2	-2	-2	1	2	0	7	1	3	1	1	2	2	2		
27528	27528	2737	266	2737	266	1	20911	21	1	18-19	FR	-1	10	10	22	22	1	3	50	-2	-2	-2	-2	-2	1	5	0	4	1	3	1	3	2	2		
27529	27529	1647	838	1647	838	1	20909	31	1	60-64	FR	-1	10	10	22	22	2	5	10	1	20	4	7	2	1	2	3	0	6	3	4	1	1	2	2	
27530	27530	1263	112	1263	112	1	20911	31	1	20-44	FR	-1	10	10	22	22	2	30	-2	-2	-2	-2	-2	1	3	0	1	1	2	2	2	3	2	2		
27532	27532	1337	839	1337	839	1	20910	21	1	35-39	FR	-1	10	10	22	22	2	35	30	-2	-2	-2	-2	-2	1	2	0	3	2	2	3	2	3	2		
27533	27533	1785	890	1785	890	1	20909	31	1	15-17	FR	-1	10	10	10	10	2	50	-2	-2	-2	-2	-2	-2	1	6	1	4	1	1	1	2	3	2		
27535	27535	1782	229	1782	229	1	20909	31	2	40-44	FR	-1	10	10	10	10	2	3	10	1	20	3	7	1	1	2	2	0	3	4	1	2	3	2	2	
27536	27536	2435	909	2435	909	1	20909	31	1	75-79	FR	-1	10	10	10	10	2	1	30	-2	-2	-2	-2	-2	1	2	0	2	2	3	2	2	3	2		
27537	27537	2786	655	2786	655	1	20910	21	1	45-49	FR	-1	22	22	22	22	1	45	40	-2	-2	-2	-2	-2	1	2	0	4	1	4	2	3	3	2	2	
27538	27538	1884	896	1884	896	1	20910	21	1	25-29	FR	-1	10	10	22	22	1	2	10	1	20	5	8	2	1	2	0	6	3	3	1	2	2	1	2	
27541	27541	1964	207	1964	207	1	20910	21	1	25-29	FR	-1	10	10	10	10	1	3	10	2	20	9	7	2	2	2	4	1	2	2	1	4	1	1	2	2
27543	27543	2008	506	2008	506	1	20909	31	1	35-39	FR	-1	10	10	10	10	1	30	34	-2	-2	-2	-2	-2	1	3	0	2	2	2	3	2	3	2	2	
27544	27544	1670	008	1670	008	1	20909	31	1	40-44	FR	-1	10	10	10	10	1	2	20	-2	-2	-2	-2	-2	1	1	0	1	1	4	2	1	3	2	2	
27545	27545	2152	929	2152	929	1	20909	31	1	50-54	FR	-1	10	10	10	10	1	1	10	1	20	9	7	1	2	2	0	3	1	3	1	2	2	2	2	
27547	27547	2581	367	2581	367	1	20909	31	1	30-34	FR	-1	22	22	22	22	1	2	10	1	20	7	3	1	1	2	5	3	4	2	3	2	3	2	2	

L'enquête EHIS englobant l'ensemble de la population (actifs, chômeurs, retraités, étudiants), notre étude exigeait de cibler uniquement la population active confrontée à l'absentéisme professionnel. Un filtre strict a donc été appliqué via la variable principale du statut d'activité (mainstat == 10) afin d'isoler **exclusivement les personnes en emploi** :

```
data abs <- data ehis %>%
```

```
filter(mainstat == 10)
```

Après l'application de ce filtre, la population d'étude s'est stabilisée à **7 097 observations**. Dans un second temps, nous avons opéré une réduction drastique du nombre de colonnes pour ne conserver que les **24 variables les plus pertinentes** pour notre problématique.

3.2.2. Clarification des noms de colonnes et alignement des variables

À l'état brut, les noms des colonnes de l'enquête (comme *hs1*, *pl1*, *sk1*, *al1*) étaient peu compréhensibles et rendaient l'analyse complexe. Pour y remédier, j'ai renommé chaque variable d'intérêt manière explicite (ex. : *sante_percue*, *limit_activite*, *fumeur_statut*, *alcool_frequence*).

De plus, en raison des spécificités et des évolutions des versions de l'enquête EHIS, certaines nomenclatures d'origine fluctuaient (extensions en « a » ou suffixes « 12 »). Une étape d'alignement automatique a été intégrée au script pour détecter et normaliser ces variables (notamment pour l'hospitalisation *ho12*, le renoncement *un1a/un2a* et l'alcool *al1*), évitant ainsi toute perte d'information ou erreur d'exécution.

3.2.3. Recodage des valeurs et axes d'analyse (Datavisualisation)

Pour que mes données soient correctes et faciles à utiliser, je me suis basé sur les règles de l'enquête européenne EHIS 3. Cette grande enquête étudie la santé des gens de façon très précise. Comme les réponses d'origine sont enregistrées sous forme de chiffres (1, 2, -2), j'ai changé ces codes en mots simples pour suivre les conseils officiels d'Eurostat et les études sur la santé au travail :

Profil et métier (Nomenclatures internationales) : L'enquête EHIS utilise une liste internationale appelée ISCO-08 pour classer les métiers. Elle contient au départ 10 catégories très précises. Pour éviter de surcharger mes graphiques et avoir des calculs fiables, j'ai regroupé ces métiers en 5 grands groupes (Cadres et professions intellectuelles, Professions intermédiaires, Employés et personnel de services, Ouvriers et métiers manuels, et Forces armées). Ce choix me permet de bien comparer la fatigue physique et le type de travail (travail manuel contre travail de bureau). Pour l'âge et les études, j'ai aussi suivi les conseils européens en créant 3 tranches d'âge (<30 ans, 30-50 ans, >50 ans) basées sur un calcul d'âges moyens, et 3 niveaux d'études clairs (Niveau brevet, Bac ou équivalent, Études supérieures).

État de santé (Directives de l'OMS et Eurostat) : Pour le poids (l'IMC), j'ai utilisé les 4 catégories officielles de l'Organisation Mondiale de la Santé (OMS) : Maigreur, Normal, Surpoids, Obésité. Pour la santé perçue (comment la personne se sent), j'ai résumé les 5 réponses du départ en 3 niveaux clairs (Bonne ou très bonne, Moyenne, Mauvaise ou très mauvaise). Enfin, j'ai gardé trois maladies de longue durée importantes dans l'enquête (l'asthme, les maux de dos et la dépression) pour voir plus tard leur lien direct avec les absences au travail.

Habitudes de vie (Déterminants de santé) : L'enquête s'intéresse beaucoup aux comportements qui touchent la santé. Pour le tabac, j'ai croisé le statut du fumeur et son nombre de cigarettes pour créer 4 profils (Ancien fumeur ou jamais fumé, Fumeur occasionnel, Fumeur quotidien (<20/j), Fumeur quotidien (>20/j)), en remplaçant les cases vides par un 0. Pour l'alcool, j'ai créé deux colonnes : une pour savoir si la personne boit (Oui/Non) et une pour regrouper les habitudes en 4 choix simples (Au moins une fois par semaine, Occasionnel, Jamais ou plus du tout, Non renseigné), ce qui évite de surcharger mes graphiques. Pour le sport, j'ai bien séparé l'effort physique fait pendant le travail (*effort_travail*) et le sport fait pendant

le temps libre (frequence_sport), car les études montrent qu'ils n'ont pas le même effet sur la santé des salariés.

Recours aux soins et absentéisme (Indicateurs RH) : J'ai résumé par « Oui » ou « Non » les questions sur les soins (rendez-vous médicaux, hôpital, médicaments, soins annulés) pour voir comment les salariés se soignent, en précisant pourquoi ils annulent parfois leurs rendez-vous (trop cher ou attente trop longue). Enfin, pour l'absentéisme, j'ai nettoyé les deux colonnes de l'enquête (appelées aw1 et aw2). J'ai changé le code technique -2 (qui veut dire « non concerné ») en un vrai « 0 jour » d'absence, et j'ai utilisé ma règle de secours pour corriger les réponses incomplètes. Cela me permet de séparer les salariés en deux groupes simples (absent ou non absent avec est_absent) et de compter précisément le nombre de jours manqués (jours_absence).

3.2.4 Traitements des valeurs manquantes

Pour préparer mes données et concevoir mes futurs graphiques, j'ai mis en place une stratégie bien précise pour gérer les cases vides et les erreurs du fichier. Au lieu de supprimer automatiquement toutes les lignes incomplètes, ce qui aurait fortement réduit la taille de mon échantillon, j'ai choisi d'adapter ma méthode selon l'importance et le rôle de chaque variable dans mon étude.

Tout d'abord, j'ai appliqué une règle d'exclusion stricte pour les informations capitales. J'ai ainsi supprimé de mon fichier toutes les personnes qui n'étaient pas en emploi, ainsi que celles dont on ne connaissait pas le métier (la CSP), car leur absence risquait de fausser mes calculs sur l'absentéisme. Ensuite, pour éviter de perdre inutilement d'autres profils, j'ai utilisé la logique de l'enquête pour remplacer certaines cases vides par des chiffres. Par exemple, j'ai attribué zéro cigarette aux non-fumeurs et j'ai transformé le code technique -2 en zéro jour d'absence. J'ai également créé une règle de secours qui bascule automatiquement un individu en "absent" si un nombre de jours est complété plus loin, même si la case principale était vide. Cela m'a permis de sauver de nombreuses lignes qui auraient dû finir à la poubelle. Enfin, pour les critères comme le niveau d'études, la santé perçue ou la consommation d'alcool, j'ai préféré conserver tout le monde en remplaçant simplement les cases vides par un mot clair comme "Inconnu" ou "Non renseigné".

Cette approche globale m'a permis de garder un maximum d'individus dans ma base pour mes graphiques, tout en garantissant des données parfaitement propres et cohérentes pour la suite de mes analyses.

3.2.5. Exportation des données

À l'issue de ce traitement, la table finale nette (data_clean), contenant uniquement nos 25 variables d'intérêt nettoyées et recodées, a été exportée aux formats .csv et .xlsx (sur OneDrive) afin de servir de base exclusive pour les phases d'analyse descriptive et de modélisation de l'absentéisme.

```
write.csv (data_clean, "EHIS_Final_Propriete.csv", row.names = FALSE)
```

```
openxlsx::write.xlsx(data_clean, "C:/Users/helen/OneDrive - CONSULTER IRIS UNIV POITIERS FR (Page MICROSOFT)/BUT 2/Projet stage/EHIS_Final_Propriete.xlsx")
```


3.3. Recodification finale des variables analytiques

TABLEAU DE RECODIFICATION ANALYTIQUE

EHIS Vague 3 — Correspondance et Logique des Seuils du Code R (Design Rouge)

1. PROFILS SOCIO-DÉMOGRAPHIQUES ET PROFESSIONNELS			
ANCIEN NOM DE VARIABLE	NOUVEAU NOM DE VARIABLE	NOUVELLES MODALITÉS DE RÉPONSES / DONNÉES	CE À QUOI ELLES CORRESPONDENT (DÉTAIL / SEUILS)
sex	sexe	"Homme" "Femme" "Inconnu"	"Homme" = Code d'origine 1 "Femme" = Code d'origine 2 "Inconnu" = Toutes les autres valeurs par défaut
hatlevel	education	"Niveau brevet" "Bac ou équivalent" "Études supérieures" "Non renseigné"	"Niveau brevet" = Codes ISCED 0, 1 et 2 "Bac ou équivalent" = Codes ISCED 3 et 4 "Études supérieures" = Codes ISCED 5, 6, 7 et 8 "Non renseigné" = Toutes les autres valeurs
jobisco	csp_groupe	"Cadres et professions intellectuelles" "Professions intermédiaires" "Employés et personnel de services" "Ouvriers et métiers manuels" "Forces armées" "Non renseigné/inactif"	"Cadres et professions intellectuelles" = Premier chiffre de jobisco vaut 1 ou 2 "Professions intermédiaires" = Premier chiffre de jobisco vaut 3 "Employés et personnel de services" = Premier chiffre de jobisco vaut 4 ou 5 "Ouvriers et métiers manuels" = Premier chiffre de jobisco vaut 6, 7, 8 ou 9 "Forces armées" = Premier chiffre de jobisco vaut 0 "Non renseigné/inactif" = Toutes les autres valeurs (NA)
age	age_individu	Valeurs numériques continues (16, 19, 22, 27, 32, 37, 42, 47, 52, 57, 62, 67, 72, 77, 82, 87)	Âges médians calculés à partir du texte initial : "15-17"=16, "18-19"=19, "20-24"=22, "25-29"=27, "30-34"=32, "35-39"=37, "40-44"=42, "45-49"=47, "50-54"=52, "55-59"=57, "60-64"=62, "65-69"=67, "70-74"=72, "75-79"=77, "80-84"=82, "85+"=87
age	tranche_age	"<30" "30-50" ">50" "Non renseigné"	"<30" = Individus de moins de 30 ans (age_individu) "30-50" = Individus de 30 à 50 ans (age_individu) ">50" = Individus de plus de 50 ans (age_individu) "Non renseigné" = Toutes les autres valeurs (NA)
2. SANTÉ GÉNÉRALE ET PATHOLOGIES CHRONIQUES			
Ancien nom de variable	Nouveau nom de variable	Nouvelles modalités de réponses / données	Ce à quoi elles correspondent (Détail / Seuils)
bmi	imc_categorie	"Maigre" "Normal" "Surpoids" "Obésité" "Inconnu"	"Maigre" = IMC strictement inférieur à 18.5 (imc_valeur) "Normal" = IMC compris entre 18.5 et 25 exclu (imc_valeur) "Surpoids" = IMC compris entre 25 et 30 exclu (imc_valeur) "Obésité" = IMC supérieur ou égal à 30 (imc_valeur) "Inconnu" = Toutes les autres valeurs
hs1	sante_percue	"Bonne ou très bonne" "Moyenne" "Mauvaise ou très mauvaise" "Inconnu"	"Bonne ou très bonne" = Codes 1 et 2 "Moyenne" = Code 3 "Mauvaise ou très mauvaise" = Codes 4 et 5 "Inconnu" = Toute autre valeur par défaut
cd1a	mal_asthme	"Oui" "Non"	"Oui" = Code d'origine 1 "Non" = Toutes les valeurs différentes de 1
cd1c	mal_dos	"Oui" "Non"	"Oui" = Code d'origine 1 "Non" = Toutes les valeurs différentes de 1

2. SANTÉ GÉNÉRALE ET PATHOLOGIES CHRONIQUES

Ancien nom de variable	Nouveau nom de variable	Nouvelles modalités de réponses / données	Ce à quoi elles correspondent (Détail / Seuils)
cd1l	mal_depression	"Oui" "Non"	"Oui" = Code d'origine 1 "Non" = Toutes les valeurs différentes de 1

3. DÉTERMINANTS DE SANTÉ ET HABITUDES DE VIE

Ancien nom de variable	Nouveau nom de variable	Nouvelles modalités de réponses / données	Ce à quoi elles correspondent (Détail / Seuils)
sk1	fumeur_statut	"Quotidien" "Occasionnel" "Non-fumeur"	"Quotidien" = Code 1 "Occasionnel" = Code 2 "Non-fumeur" = Code 3 ou toute autre valeur par défaut
sk2	nb_cigarettes	Valeur numérique ≥ 0	Nombre brut de cigarettes par jour si ≥ 0. Devient 0 si la valeur d'origine est négative ou manquante (NA).
sk1 / sk2	tranche_cigarettes	"Ancien fumeur ou jamais fumé" "Fumeur occasionnel" "Fumeur quotidien (<20/j)" "Fumeur quotidien (>20/j)"	"Ancien fumeur ou jamais fumé" = Si fumeur_statut est "Non-fumeur" "Fumeur occasionnel" = Si fumeur_statut est "Occasionnel" "Fumeur quotidien (<20/j)" = Si quotidien ET nb_cigarettes ≤ 20 "Fumeur quotidien (>20/j)" = Si quotidien ET nb_cigarettes > 20
al1 / v_al1	alcool_statut	"Oui" "Non" "Non renseigné"	"Oui" = Codes d'origine de 1 à 7 (v_al1) "Non" = Codes d'origine 8 et 9 (v_al1) "Non renseigné" = Toutes les autres valeurs (NA)
al1 / v_al1	alcool_frequence	"Au moins une fois par semaine" "Occasionnel (Moins d'une fois par semaine)" "Jamais ou plus du tout" "Non renseigné"	"Au moins une fois par semaine" = Codes 1 à 4 (v_al1) "Occasionnel (Moins d'une fois par semaine)" = Codes 5 à 7 (v_al1) "Jamais ou plus du tout" = Codes 8 et 9 (v_al1) "Non renseigné" = Toutes les autres valeurs
pe1	effort_travail	"Faible effort (Assis/Debout)" "Effort modéré (Marche modéré)" "Effort intense (Physique intense)" "Pas concerné (sans emploi)" "Non renseigné"	"Faible effort (Assis/Debout)" = Code 1 "Effort modéré (Marche modéré)" = Code 2 "Effort intense (Physique intense)" = Code 3 "Pas concerné (sans emploi)" = Code 4 "Non renseigné" = Toute autre valeur
pe6_num	frequence_sport	"Jamais" "1 à 2 fois par semaine" "3 jours ou plus par semaine" "Non renseigné"	"Jamais" = Code 0 "1 à 2 fois par semaine" = Codes 1 et 2 "3 jours ou plus par semaine" = Codes 3 à 7 "Non renseigné" = Si la valeur est manquante (NA) ou autre

4. SYSTÈME DE RECOURS AUX SOINS ET RENONCEMENT

Ancien nom de variable	Nouveau nom de variable	Nouvelles modalités de réponses / données	Ce à quoi elles correspondent (Détail / Seuils)
am1 / am2 / v_am	consult_med_12_derniers_mois	"Oui" "Non"	"Oui" = Si la variable v_am vaut 1 "Non" = Si v_am est différente de 1 ou manquante (NA)
ho12 / v_ho	hospitalise	"Oui" "Non"	"Oui" = Si la variable v_ho vaut 1 "Non" = Si v_ho est différente de 1 ou manquante (NA)
md1	prise_medicaments	"Oui" "Non"	"Oui" = Code d'origine 1 "Non" = Toutes les valeurs différentes de 1

4. SYSTÈME DE RECOURS AUX SOINS ET RENONCEMENT

Ancien nom de variable	Nouveau nom de variable	Nouvelles modalités de réponses / données	Ce à quoi elles correspondent (Détail / Seuils)
un1a / un2a	renoncement_soins	"Oui" "Non"	"Oui" = Si la variable v_un1 vaut 1 OU si v_un2 vaut 1 "Non" = Dans tous les autres cas
un1a / un2a	raison_renoncement_soins	"Prix et Délais trop longs" "Raison financière (Trop cher)" "Délais d'attente trop longs" "Non concerné"	"Prix et Délais trop longs" = Si v_un1 == 1 et v_un2 == 1 "Raison financière (Trop cher)" = Si v_un1 == 1 (uniquement) "Délais d'attente trop longs" = Si v_un2 == 1 (uniquement) "Non concerné" = Si v_un1 == 2 et v_un2 == 2, ou tout autre cas par défaut

5. VARIABLES D'ABSENTÉISME (VARIABLES CIBLES)

Ancien nom de variable	Nouveau nom de variable	Nouvelles modalités de réponses / données	Ce à quoi elles correspondent (Détail / Seuils)
aw1	est_absent	"Oui" (1) "Non" (0)	"Oui" (1) = Code d'origine aw1 == 1 "Non" (0) = Toutes les valeurs différentes de 1 Logique de récupération : si aw1 manquant mais aw2 > 0, est_absent = 1
aw2	jours_absence	"0" "Non renseigné" Nombre de jours (ex: "5", "14" ...)	"0" = Si aw1 n'est pas égal à 1 (non absent) ou aw2 == -2 "Non renseigné" = Si aw1 == 1 mais aw2 est manquant (NA) ou négatif (<0) Valeur de aw2 convertie en texte = Si aw1 == 1 et la saisie de aw2 est valide

3.4 Architecture et structure de l'outil de datavisualisation

3.4.1 Le choix de R Shiny

L'application a été entièrement développée avec R Shiny, un package du langage R qui permet de transformer des analyses de données en une application web interactive. Son fonctionnement repose sur une séparation claire entre deux éléments principaux :

L'Interface Utilisateur (UI) : C'est la partie "visible" du tableau de bord. Elle définit l'emplacement des titres, des graphiques et des indicateurs. Pour rompre avec le design classique de R Shiny et lui donner un aspect moderne proche de Microsoft Power BI, du code CSS sur mesure a été intégré (choix des polices, bordures fines, organisation des éléments en grilles régulières).

Le Serveur (Server) : C'est le "cerveau" de l'application. Il charge le fichier de données (EHIS_Final_Propriete.csv), prépare les variables (comme le tri des âges ou des diplômes dans le bon ordre) et calcule automatiquement les indicateurs et les graphiques interactifs qui seront affichés dans l'UI.

3.4.2 Structure et identité visuelle du Tableau de Bord


Le tableau de bord est conçu comme une page unique (Single-Page) que l'utilisateur fait défiler du haut vers le bas.

Identité visuelle et choix des couleurs :


La charte graphique de l'application repose sur une palette épurée de nuances de bordeaux et de rosé. Ce choix colorimétrique a été spécifiquement adopté pour reprendre l'identité visuelle et les couleurs officielles de la FEAA (Faculté d'Économie et d'Administration des Affaires) de l'Université de Iași, permettant ainsi d'ancrer l'outil dans son contexte institutionnel d'origine.

L'interface s'organise ensuite en plusieurs blocs logiques :


- **Le bandeau d'indicateurs clés (KPI) :** Placé tout en haut, il affiche instantanément les chiffres globaux essentiels : le nombre total d'individus analysés, le taux d'absentéisme global, l'âge moyen de l'échantillon et la durée médiane des arrêts.
- **La description de la population :** Avant d'analyser l'absentéisme, cette section montre la répartition globale de l'échantillon (sexe, âge, diplôme, CSP, santé) à l'aide de micro-barres horizontales légères.




- **Le bloc "Santé Perçue"** : Il croise l'état de santé subjectif avec l'absentéisme via deux graphiques. Le premier montre la proportion d'absents/présents (barres empilées à 100%), le second montre l'évolution du nombre de jours d'arrêt (courbe).
- **Les facteurs professionnels** : Cette zone étudie l'impact du métier (un graphique à bulles pour les CSP) et de la pénibilité physique (un graphique combinant des barres pour le taux d'absence et une ligne pour la durée en jours).



- **Les écarts démographiques** : Un graphique en "haltères" (Dumbbell chart) permet de comparer d'un seul coup d'œil l'écart de taux d'absentéisme entre les hommes et les femmes pour chaque tranche d'âge.
- **Les habitudes de vie** : Trois graphiques simples analysent l'impact du tabagisme, de la corpulence (catégories d'IMC) et de la fréquence de l'activité sportive sur l'absence.



- **Le parcours de soins et les maladies** : * Un graphique "radar" (en toile d'araignée) montre si les personnes ayant recours aux soins (médicaments, hospitalisation) s'absentent plus que la moyenne nationale.
- **La distribution des durées** : Tout en bas, un histogramme détaillé présente la répartition exacte du nombre de jours d'absence pour comprendre si les arrêts de travail de la base sont plutôt courts ou longs.



Tous les graphiques intègrent la technologie Plotly, ce qui permet à l'utilisateur de passer sa souris sur une barre ou un point pour voir s'afficher instantanément les valeurs exactes et les pourcentages calculés.

3.5 Analyse des résultats : les variables clés de l'absentéisme selon la datavisualisation

L'analyse visuelle des graphiques du tableau de bord permet d'identifier et de classer rapidement les variables qui influencent le plus l'absentéisme (en fréquence et en durée).

3.5.1 Les facteurs de santé (L'impact majeur)

Cette section constitue le principal déterminant de l'absentéisme :

- **La santé perçue (sante_percue) :** C'est le premier indicateur. Le graphique en barres empilées montre que l'absentéisme devient majoritaire chez les personnes en « Mauvaise » ou « Très mauvaise » santé. La courbe associée confirme que ces profils s'arrêtent aussi beaucoup plus longtemps.
- **La dépression (mal_depression) :** Sur le graphique des maladies chroniques, c'est la dépression qui affiche l'écart de hauteur le plus net entre les malades et les non-malades, surpassant le mal de dos ou l'asthme.
- **Le recours aux soins (hospitalise, prise_medicaments) :** Sur le graphique radar, la surface bordeaux s'étire massivement vers ces deux critères, dépassant largement la ligne pointillée de la moyenne nationale.

3.5.2 Les facteurs professionnels (L'impact du milieu)

Le travail dessine des tendances très linéaires sur les graphiques :

- **L'effort physique (effort_travail) :** Le graphique combiné montre une progression par paliers parfaits. Plus le travail demande un effort intense, plus le taux d'absence (barres) et le nombre de jours (triangles) grimpent simultanément.
- **La catégorie socio-professionnelle (csp_groupe) :** Le graphique à bulles montre une séparation nette : les cadres sont regroupés tout à gauche (faible taux), tandis que les ouvriers et employés se situent nettement à droite de la moyenne nationale.

3.5.3 Les facteurs démographiques et de style de vie (Les modérateurs)

- **Le genre (sexe)** : Le graphique en haltères (*Dumbbell chart*) montre que pour chaque tranche d'âge, le point des femmes est systématiquement situé à droite de celui des hommes (taux plus élevé).
- **Le sport (frequence_sport)** : Le graphique montre un effet "escalier descendant" parfait. Plus la pratique sportive est régulière, plus les barres rétrécissent, confirmant son rôle de facteur de protection.

En résumé : Les graphiques révèlent que la **santé perçue**, la **dépression**, l'**effort physique au travail** et la **CSP** sont les quatre variables les plus explicatives de l'absentéisme dans ce dashboard.

3.6 Création du modèle de régression logistique et résultats

3.6.1 Création du modèle

Pour comprendre ce qui déclenche vraiment l'absentéisme au travail, j'ai mené une analyse statistique sur les données de l'enquête EHIS 3 France. Pour construire cette étude de façon rigoureuse, j'ai combiné trois outils principaux :

- **La fonction relevel()** : Elle me sert à choisir mon « point de comparaison » (le groupe témoin). C'est indispensable pour savoir par rapport à quoi je calcule un risque. Par exemple, j'ai choisi de comparer les âges par rapport aux *Seniors*, et les catégories de poids par rapport à l'*Obésité*.

```
data_reg$imc_categorie <- factor(data_reg$imc_categorie)
data_reg$imc_categorie <- relevel(data_reg$imc_categorie, "Obésité")
```

- **La fonction glm()** : C'est le cœur du calcul. Elle construit mon modèle de régression logistique qui permet d'isoler l'impact pur de chaque facteur (comme le tabac, le sexe ou la santé) « toutes choses égales par ailleurs ». Cela signifie qu'elle calcule l'effet d'une variable en effaçant l'influence des autres, pour être sûr de ne pas mélanger les causes.

```
# Modèle classique avec glm() en utilisant les données de data_reg
modele_logistique <- glm(
  est_absent ~ sexe + tranche_age + imc_categorie + education + csp_groupe +
  sante_percue + fumeur_statut + alcool_statut + effort_travail +
  frequence_sport + hospitalise + prise_medicaments + renoncement_soins +
  mal_asthme + mal_dos + mal_depression,
  data = data_reg,
  family = binomial
)
```

- **Le package sjPlot** : Il me sert tout simplement à traduire les calculs mathématiques bruts en un tableau final clair, affichant directement les **Odds Ratios (OR)**.

```
# 5. Génération de la table complète (Odds Ratios, IC 95% et P-values)
sjPlot::tab_model(modele_logistique)
```

3.6.2 Classement et analyse des facteurs de risque significatifs

Pour mesurer l'impact de chaque variable, j'analyse les Odds Ratios (OR). Pour rappel, un OR supérieur à 1 indique un risque d'absence plus élevé que le groupe qui me sert de repère (la modalité de référence).

En classant mes résultats par ordre d'importance (du plus grand impact au plus petit), voici la liste exclusive des facteurs qui influencent **réellement et significativement** ($p < 0,05$) l'absentéisme dans mon étude :

- **L'hospitalisation récente (OR = 4,28)** : C'est le facteur le plus lourd de mon modèle. Avoir été hospitalisé au cours des 12 derniers mois multiplie le risque d'absence par 4,3 par rapport aux personnes « Non hospitalisées » (mon repère pour cette variable).
- **La santé perçue « Mauvaise ou très mauvaise » (OR = 4,11)** : Le risque est multiplié par un peu plus de 4,1 par rapport à une santé « Bonne ou très bonne » (mon repère pour cette variable).
- **La prise de médicaments (OR = 1,99)** : Elle presque double le risque d'absence (risque multiplié par 1,99) par rapport au fait de ne « Pas prendre de médicaments ».
- **La santé perçue « Moyenne » (OR = 1,90)** : Le risque est multiplié par 1,9 par rapport à une santé « Bonne ou très bonne ».
- **La maigreur — IMC < 18,5 (OR = 1,69)** : Elle augmente le risque d'absence de 69 % par rapport à la situation « Normale » (mon repère pour le poids).
- **L'âge — Les jeunes entrants de 15-29 ans (OR = 1,65)** : Ils ont 65 % de risques en plus d'être absents par rapport à la catégorie des « Seniors (>50 ans) » (mon repère pour l'âge).
- **Le renoncement aux soins (OR = 1,46)** : Avoir déjà dû renoncer à se soigner augmente le risque d'absence de 46 % par rapport à ceux qui n'ont « Pas renoncé » aux soins.
- **L'âge — Les actifs confirmés de 30-50 ans (OR = 1,43)** : Ils ont 43 % de risques en plus d'être absents par rapport aux « Seniors (>50 ans) ».
- **Le tabagisme quotidien (OR = 1,30)** : Les fumeurs réguliers ont 30 % de risques supplémentaires d'être absents que les « Non-fumeurs » (mon repère pour le tabac).
- **Le sexe féminin (OR = 1,21)** : Les femmes ont 21 % de risques en plus de s'absenter par rapport aux « Hommes ».

-
- **Un travail physique intense (OR = 1,21)** : Il augmente le risque de 21 % par rapport à un emploi nécessitant un « Faible effort (Assis/Debout) » (mon repère pour l'effort au travail).
 - **La consultation médicale récente (OR = 1,16)** : Avoir consulté un médecin au cours des 12 derniers mois augmente le risque d'absence de 16 % par rapport à ceux qui n'ont « Pas consulté ».

3.6.4 Confrontation avec la littérature et conclusions

Mes conclusions statistiques s'accordent très bien avec les études et baromètres existants, ce qui valide ma démarche :

- **La santé** : Le fait que la santé perçue mauvaise (OR = 4,11), les hospitalisations récentes (OR = 4,28) et la prise de traitements (OR = 1,99) soient les causes majeures d'absence est une évidence confirmée par l'**Observatoire APICIL (2025)** et les données de l'**Assurance Maladie**, qui placent la morbidité réelle au premier rang des motifs d'arrêt.
- **Le facteur de l'âge** : Mon modèle prouve mathématiquement que l'absentéisme décroît avec l'âge sur mon échantillon. Les seniors (>50 ans) s'absentent moins souvent que les jeunes de 15-29 ans (OR = 1,65) et les actifs de 30-50 ans (OR = 1,43). Cela valide parfaitement les observations du **Baromètre Malakoff Humanis**, qui montre un "paradoxe de l'âge" : les jeunes ont une prévalence très élevée d'arrêts courts (fréquence), tandis que les seniors ont des arrêts rares mais beaucoup plus longs. Mon modèle mesurant le fait d'avoir eu au moins un arrêt (la fréquence), les jeunes ressortent logiquement comme les plus à risque.
- **Le sexe et les habitudes de vie** : L'écart de 21 % au détriment des femmes (OR = 1,21) rejoint les constats de **Verlingue (2025)** et de la **DARES**, qui l'expliquent par des inégalités structurelles (charge mentale, gestion des imprévus familiaux comme la garde d'enfants, et métiers à forte usure relationnelle). De même, le tabagisme quotidien augmente significativement le risque de 30 % (OR = 1,30), ce qui valide les rapports de **Santé Publique France** sur l'impact des comportements à risque. Enfin, mon modèle apporte un éclairage intéressant sur le poids : la maigreur s'impose ici comme un facteur de fragilité physique marquant (OR = 1,69) par rapport au poids « Normal » choisi comme repère, un phénomène documenté par l'**Inserm** où un IMC inférieur à 18,5 est un marqueur de vulnérabilité immunitaire et de fatigue.

À l'inverse, la catégorie professionnelle (CSP), la consommation d'alcool, la pratique du sport, ou le fait d'avoir un surpoids ou une obésité n'ont pas d'impact direct et significatif sur le risque d'absence dans mon modèle. J'en conclus que ces variables ne sont pas sans effet dans la vraie vie, mais que leur influence est indirecte : elle passe "en bruit de fond" à travers d'autres éléments majeurs comme la santé perçue ou le renoncement aux soins (OR = 1,46). Ce mécanisme de médiation est d'ailleurs largement documenté par le cadre des déterminants sociaux de la santé de l'**OMS** et les rapports de la **DREES (2005)** et d'**Asterès (2025)**.

PARTIE IV : Retour d'expérience et bilan du projet

4.1 Difficultés rencontrées lors du projet

Ce projet a présenté plusieurs difficultés, tant sur le plan technique que relationnel. Tout d'abord, comprendre et préparer les données a été compliqué car toute la documentation et l'explication des variables étaient en anglais. De plus, l'utilisation de RStudio a été un vrai défi : n'étant pas à l'aise avec le langage R, j'ai eu du mal à comprendre le fonctionnement du logiciel et à corriger les erreurs dans mon code. Enfin, la communication avec M. Jemna n'a pas toujours été facile. La barrière de la langue a rendu l'explication des consignes assez difficile au début, ce qui a compliqué la compréhension de ses attentes pour le projet.

4.2 Compétences Techniques et Analytiques Acquises

Mon stage au sein du Laboratoire d'Économie et Statistiques de l'Université de Iași m'a permis d'acquérir et de perfectionner un ensemble diversifié de compétences de pointe en science des données. Travailler de manière autonome sur un projet de recherche concret m'a confrontée à toutes les étapes de la valorisation de la donnée.

Maîtrise approfondie de RStudio et gestion de données massives : J'ai consolidé mes bases en programmation en utilisant de manière intensive le langage R et le package tidyverse. J'ai appris à traiter un jeu de données volumineux (14 192 lignes à l'origine) en appliquant des filtres stricts pour isoler la population active, en gérant les valeurs manquantes ou aberrantes, et en automatisant la normalisation des variables complexes (comme le regroupement des catégories professionnelles de la nomenclature ISCO-08).

Développement d'applications web et Datavisualisation (R Shiny) : Cette expérience a marqué ma première opportunité de concevoir un outil décisionnel interactif de A à Z. J'ai maîtrisé l'architecture UI/Server de R Shiny et intégré du code CSS sur mesure pour adapter l'interface aux couleurs de la faculté d'accueil (FEAA). L'intégration de la technologie Plotly m'a permis de rendre les graphiques dynamiques pour explorer visuellement les mouvements et les tendances de l'absentéisme.

Modélisation statistique et interprétation scientifique : Au-delà de l'analyse descriptive, j'ai développé des compétences en modélisation avancée en construisant un modèle de régression logistique. J'ai appris à interpréter mathématiquement et concrètement les Odds Ratios (OR) pour identifier et hiérarchiser les véritables facteurs de risque de l'absentéisme (comme l'impact d'une hospitalisation ou du renoncement aux soins), tout en confrontant mes résultats statistiques aux publications de la littérature épidémiologique contemporaine.

4.3 Développement Personnel et Adaptation Culturelle

Ce stage à l'Université Alexandru Ioan Cuza de Iași représente une étape charnière et déterminante de mon parcours. D'un point de vue technique, il m'a permis de faire le lien entre la théorie et la pratique en appliquant la science des données à un enjeu de santé publique majeur : l'absentéisme au travail en France. D'un point de vue humain, il m'a ouverte à l'international et a révélé ma capacité à mener un projet analytique complet en toute autonomie.

Pour ce qui est du cadre professionnel au sein du laboratoire, mes échanges se sont concentrés de manière privilégiée avec mon tuteur, Monsieur Danut Jemna. Cet accompagnement direct m'a permis de comprendre les exigences de la recherche et de m'adapter efficacement à sa méthode de travail.

En parallèle, ma vie en dehors du laboratoire a été particulièrement enrichissante grâce à de nombreuses rencontres avec des personnes venant d'endroits et d'horizons très variés. Ces moments de partage m'ont permis de m'ouvrir et de comprendre de nombreuses autres cultures, élargissant mes perspectives bien au-delà de la seule culture roumaine. En somme, ce mélange entre rigueur académique et vie quotidienne cosmopolite a considérablement renforcé ma confiance en ma capacité à m'adapter à des environnements diversifiés.

4.4 CONCLUSION

En conclusion, ce stage à l'Université de Iași a été une expérience très importante, tant sur le plan étudiant que personnel. Même si le début a été difficile à cause de RStudio, des documents en anglais et de la barrière de la langue avec M. Jemna, réussir à gérer ce projet de science des données de A à Z toute seule m'a appris à être très organisée et m'a donné beaucoup plus de confiance en moi face à des tâches nouvelles.

Concernant mon avenir professionnel, ce projet m'a beaucoup aidée à y voir plus clair. J'ai vraiment aimé travailler sur le sujet de l'absentéisme, qui est très important pour la société. Cependant, cette expérience m'a aussi fait réfléchir à ce que je veux vraiment pour la suite : j'ai réalisé que je ne voulais pas faire ce métier toute ma vie, ni rester dans ce domaine à long terme. Ce n'est pas du tout un échec, c'est au contraire une étape très utile qui m'aide à savoir ce qui me correspond vraiment et à mieux choisir mon orientation.

Enfin, ce premier voyage professionnel m'a surtout donné une grande envie de découvrir le monde. L'aventure humaine que j'ai vécue en Roumanie me pousse aujourd'hui à voir plus grand. Plus tard, je veux avoir un parcours professionnel flexible qui me permettra de changer de pays et de découvrir de nouvelles cultures. Je termine ce stage en sachant que tout ce que j'ai appris en analyse de données me sera, dans tous les cas, très utile pour la suite.

ANNEXE

Code traitement des données

```
# Chargement des packages R indispensables
library(dplyr) # Manipulation des données (mutate, select, filter)
library(janitor) # Nettoyage des noms de colonnes avec clean_names()
library(openxlsx) # Exportation propre vers Excel (.xlsx)

# -----
# 1. IMPORTATION AND FILTRE DE BASE
# -----

# Importation du fichier CSV (séparateur point-virgule et mise en minuscules automatique)
data_ehis <- read.csv2(file.choose(), header = TRUE, stringsAsFactors = FALSE) %>%
  clean_names()

# Filtre strict pour ne garder que les personnes en emploi (mainstat == 10)
data_abs <- data_ehis %>%
  filter(mainstat == 10)

# -----
# 2. ALIGNEMENT AUTOMATIQUE DES VARIABLES DE L'ENQUÊTE
# -----
# Cette étape détecte si vos variables utilisent les extensions "a" ou "12"
# spécifiques à certaines versions de l'EHIS, afin d'éviter l'erreur "objet introuvable".

# Consultation médicale (Généraliste ou spécialiste sur les 12 derniers mois)
v_am = if("am1" %in% names(data_abs)) data_abs$am1 else if("am2" %in% names(data_abs)) data_abs$am2 else NA

# Hospitalisation (Utilisation de la variable ho12)
v_ho = if("ho12" %in% names(data_abs)) data_abs$ho12 else NA

# Renoncement aux soins (Utilisation des variables exactes un1a et un2a)
v_un1 = if("un1a" %in% names(data_abs)) data_abs$un1a else NA
v_un2 = if("un2a" %in% names(data_abs)) data_abs$un2a else NA

# Alcool (Sécurité de détection de la colonne al1)
v_al1 = if("al1" %in% names(data_abs)) data_abs$al1 else NA

# -----
# 3. RECODAGE DES VARIABLES (LOGIQUE ET SÉCURITÉS INTEGREGES)
# -----

data_abs <- data_abs %>%
  mutate(

    # --- Profil sociodémographique et Tranches d'âge ---
    # Convertit le sexe : 1 = Homme, 2 = Femme
    sexe = recode(as.character(sex), "1" = "Homme", "2" = "Femme", .default = "Inconnu"),

    # Niveau d'études basé sur les standards de la variable hatlevel
    education = case_when(
      hatlevel %in% 0:2 ~ "Niveau brevet",
      hatlevel %in% 3:4 ~ "Bac ou équivalent",
      hatlevel %in% 5:8 ~ "Études supérieures",
      TRUE ~ "Non renseigné"
    ),

    # --- AJOUT DE LA CSP (Basé sur la variable officielle 'Occupation in main job' ISCO-08) ---
    csp_code = substr(as.character(jobisco), 1, 1),
```

```

csp_groupe = case_when(
  csp %in% c(1, 2) ~ "Cadres et professions intellectuelles",
  csp %in% c(3) ~ "Professions intermédiaires",
  csp %in% c(4, 5) ~ "Employés et personnel de services",
  csp %in% c(6, 7, 8, 9) ~ "Ouvriers et métiers manuels",
  csp == 0 ~ "Forces armées",
  TRUE ~ "Non renseigné"
),

age_reel = age,

age_individu = case_when(
  age == "15-17" ~ 16, age == "18-19" ~ 19, age == "20-24" ~ 22,
  age == "25-29" ~ 27, age == "30-34" ~ 32, age == "35-39" ~ 37,
  age == "40-44" ~ 42, age == "45-49" ~ 47, age == "50-54" ~ 52,
  age == "55-59" ~ 57, age == "60-64" ~ 62, age == "65-69" ~ 67,
  age == "70-74" ~ 72, age == "75-79" ~ 77, age == "80-84" ~ 82,
  age == "85+" ~ 87, TRUE ~ NA_real_
),

# Regroupement des tranches d'âge
tranche_age = case_when(
  age_individu < 30 ~ "<30",
  age_individu >= 30 & age_individu <= 50 ~ "30-50",
  age_individu > 50 ~ ">50",
  TRUE ~ "Non renseigné"
),

# --- Santé Générale et IMC ---
imc_valeur = as.numeric(bmi),
imc_categorie = case_when(
  imc_valeur < 18.5 ~ "Maigreur",
  imc_valeur >= 18.5 & imc_valeur < 25 ~ "Normal",
  imc_valeur >= 25 & imc_valeur < 30 ~ "Surpoids",
  imc_valeur >= 30 ~ "Obésité",
  TRUE ~ "Inconnu"
),

sante_percue = case_when(
  as.character(hs1) %in% c("1", "2") ~ "Bonne ou très bonne",
  as.character(hs1) == "3" ~ "Moyenne",
  as.character(hs1) %in% c("4", "5") ~ "Mauvaise ou très mauvaise",
  TRUE ~ "Inconnu"
),

# --- Habitudes de Vie : Tabac ---
fumeur_statut = recode(as.character(sk1), "1"="Quotidien", "2"="Occasionnel", "3"="Non-fumeur", .default="Non-fumeur"),
nb_cigarettes = as.numeric(sk2),
nb_cigarettes = ifelse(nb_cigarettes < 0 | is.na(nb_cigarettes), 0, nb_cigarettes),

tranche_cigarettes = case_when(
  fumeur_statut == "Non-fumeur" ~ "Ancien fumeur ou jamais fumé",
  fumeur_statut == "Occasionnel" ~ "Fumeur occasionnel",
  fumeur_statut == "Quotidien" & nb_cigarettes <= 20 ~ "Fumeur quotidien (<20/j)",
  fumeur_statut == "Quotidien" & nb_cigarettes > 20 ~ "Fumeur quotidien (>20/j)",
  TRUE ~ "Non renseigné"
),

# ----- ALCOOL -----
alcool_statut = case_when(
  v_all %in% 1:7 ~ "Oui",
  v_all %in% 8:9 ~ "Non",
  TRUE ~ "Non renseigné"
),

alcool_frequence = case_when(
  v_all %in% 1:4 ~ "Au moins une fois par semaine",
  v_all %in% 5:7 ~ "Occasionnel (Moins d'une fois par semaine)",
  v_all %in% 8:9 ~ "Jamais ou plus du tout",
  TRUE ~ "Non renseigné"
),

# --- Habitudes de Vie : Activité Physique & Sport ---
effort_travail = case_when(
  pe1 == 1 ~ "Faible effort (Assis/Debout)",
  pe1 == 2 ~ "Effort modéré (Marche modéré)",
  pe1 == 3 ~ "Effort intense (Physique intense)",
  pe1 == 4 ~ "Pas concerné (sans emploi)",
  TRUE ~ "Non renseigné"
),

frequence_sport = case_when(
  is.na(v_pe6) ~ "Non renseigné",
  v_pe6 == 0 ~ "Jamais",
  v_pe6 %in% 1:2 ~ "1 à 2 fois par semaine",
  v_pe6 %in% 3:7 ~ "3 jours ou plus par semaine",
  TRUE ~ "Non renseigné"
),

```

```

frequence_sport = factor(frequence_sport, levels = c("Jamais", "1 à 2 fois par semaine", "3 jours ou plus par semaine", "Non renseigné")),
effort_travail = factor(effort_travail, levels = c("Faible effort (Assis/Debout)", "Effort modéré (Marche modéré)", "Effort intense (Physique intense)", "Non renseigné")),

# --- Système de Recours aux Soins et Renoncement ---
consult_med_12_derniers_mois = ifelse(!is.na(v_am) & v_am == 1, "Oui", "Non"),
hospitalise = ifelse(!is.na(v_ho) & v_ho == 1, "Oui", "Non"),
prise_medicaments = ifelse(md1 == 1, "Oui", "Non"),
renoncement_soins = ifelse((!is.na(v_un1) & v_un1 == 1) | (!is.na(v_un2) & v_un2 == 1), "Oui", "Non"),

raison_renoncement_soins = case_when(
  v_un1 == 1 & v_un2 == 1 ~ "Prix et Délais trop longs",
  v_un1 == 1 ~ "Raison financière (Trop cher)",
  v_un2 == 1 ~ "Délais d'attente trop longs",
  v_un1 == 2 & v_un2 == 2 ~ "Non concerné",
  TRUE ~ "Non concerné"
),

# --- Absentéisme au Travail (AW1 et AW2) ---
jours_absence = case_when(
  aw2 == -2 ~ "0",
  is.na(aw2) & aw1 == 1 ~ "Non renseigné",
  is.na(aw2) ~ "0",
  TRUE ~ as.character(aw2)
),

est_absent = case_when(
  aw1 == 1 ~ 1,
  aw1 %in% c(2, -2) ~ 0,
  # Logique de secours / récupération : si aw1 est manquant mais aw2 indique des jours d'absence
  is.na(aw1) & as.numeric(aw2) > 0 & aw2 != -2 ~ 1,
  TRUE ~ 0
),

# --- Maladies Chroniques ---
mal_asthme = ifelse(cd1a == 1, "Oui", "Non"),
mal_dos = ifelse(cd1c == 1, "Oui", "Non"),
mal_depression = ifelse(cd1l == 1, "Oui", "Non")
) %>%
filter(
  effort_travail != "Pas concerné (sans emploi)",
  csp_groupe != "Non renseigné"
)

#
# 4. SÉLECTION FINALE ET EXPORTATION
# -----

data_clean <- data_abs %>%
select(
  sexe, age_reel, age_individu, tranche_age, imc_categorie, education, csp_groupe,
  sante_percue, fumeur_statut, nb_cigarettes, tranche_cigarettes,
  alcool_statut, alcool_frequence,
  effort_travail, frequence_sport,
  consult_med_12_derniers_mois, hospitalise, prise_medicaments,
  renoncement_soins, raison_renoncement_soins,
  est_absent, jours_absence,
  mal_asthme, mal_dos, mal_depression
)

# Enregistrement des données
write.csv(data_clean, "EHIS_Final_Propre.csv", row.names = FALSE)
openxlsx::write.xlsx(data_clean, "C:/Users/helen/OneDrive - CONSULTER IRIS UNIV POITIERS FR (Page MICROSOFT)/BUT 2/Projet stage/EHIS_Final_Propre.xlsx")

```

Code création dataviz avec RShiny

```
library(shiny) # Framework principal pour l'application web interactive
library(dplyr) # Manipulation et nettoyage de données (pipes %%, mutate, group_by)
library(tidyr) # Restructuration des données (pivot_wider pour le dumbbell chart)
library(plotly) # Création de graphiques interactifs et esthétiques

# =====
# 1. CHARGEMENT SECURISE ET PREPARATION DES DONNEES
# =====

fichier <- "EHIS_Final_Propre.csv"
df <- read.csv(fichier, stringsAsFactors = FALSE, encoding = "UTF-8")

# SECURITE : Si R ne trouve qu'une seule colonne, cela signifie que le vrai séparateur
# est le point-virgule (;). On rélit alors le fichier avec le bon paramètre.
if (ncol(df) == 1) {
  df <- read.csv(fichier, sep = ";", stringsAsFactors = FALSE, encoding = "UTF-8")
}

# ALIGNEMENT : 'est_absent' est déjà codé en 0/1 (numérique) dans le script de nettoyage V8
df$absent_num <- df$est_absent

# SECURITE JOURS : On crée une version purement numérique pour les calculs (les "Non renseigné" deviennent NA)
df$jours_absence_num <- as.numeric(df$jours_absence)

# Transformation des colonnes textuelles en FACTEURS ORDONNES (Mis à jour selon V8)
df <- df %>%
  mutate(
    tranche_age = factor(tranche_age, levels = c("<30", "30-50", ">50")),
    education = factor(education, levels = c("Niveau brevet", "Bac ou équivalent", "Études supérieures", "Non renseigné")),
    imc_categorie = factor(imc_categorie, levels = c("Maigre", "Normal", "Surpoids", "Obésité", "Inconnu")),
    sante_percue = factor(sante_percue, levels = c("Bonne ou très bonne", "Moyenne", "Mauvaise ou très mauvaise", "Inconnu")),
    effort_travail = factor(effort_travail, levels = c("Faible effort (Assis/Debout)", "Effort modéré (Marche modéré)", "Effort intense (Physique intense)", "Non renseigné")),
    frequence_sport = factor(frequence_sport, levels = c("Jamais", "1 à 2 fois par semaine", "3 jours ou plus par semaine", "Non renseigné")),
    fumeur_statut = factor(fumeur_statut, levels = c("Non-fumeur", "Occasionnel", "Quotidien")),
    alcool_frequence = factor(alcool_frequence, levels = c("Au moins une fois par semaine", "Occasionnel (Moins d'une fois par semaine)", "Jamais ou plus du tout", "Non renseigné")),
    csp_groupe = factor(csp_groupe, levels = c("Cadres et professions intellectuelles", "Professions intermédiaires", "Employés et personnel de services", "Ouvriers et métiers mar
  )

# Définition des palettes de couleurs graphiques (Dégradés de bordeaux/rosé style Power BI)
GRAD_2 <- c("#8B0000", "#E3A8A8")
GRAD_3 <- c("#8B0000", "#B23A48", "#E3A8A8")
GRAD_4 <- c("#400000", "#8B0000", "#B23A48", "#E3A8A8")
GRAD_5 <- c("#4A0000", "#6B0000", "#8B0000", "#B23A48", "#E3A8A8")
GRAD_6 <- c("#4A0000", "#6B0000", "#8B0000", "#A62424", "#C75252", "#E88888")

# =====
# 2. UI (INTERFACE UTILISATEUR) : DESIGN SINGLE-PAGE STYLE POWER BI
# =====
ui <- fluidPage(
  title = "EHIS 3 France – Déterminants de l'absentéisme",

  # BALISE HEAD : Contient le style CSS personnalisé pour casser le look par défaut de Shiny
  tags$head(
    tags$style(HTML("
      /* Configuration générale de la page */
      * { box-sizing: border-box; margin: 0; padding: 0; }
      body { font-family: -apple-system, BlinkMacSystemFont, 'Segoe UI', sans-serif; background: #f5f4f0; color: #1a1a18; padding: 2rem; }

      /* Titres et sous-titres */
      h1 { font-size: 24px; font-weight: 700; color: #8B0000; margin-bottom: 4px; }
      .subtitle { font-size: 13px; color: #666; margin-bottom: 2rem; }

      /* Séparateurs de sections (Bandeaux bordeaux) */
      .block-title { font-size: 11px; font-weight: 700; letter-spacing: 0.1em; text-transform: uppercase; color: #8B0000; margin: 2.5rem 0 12px; border-bottom: 2px solid #8B0000; }

      /* Design des cartes KPI (Indicateurs clés du haut) */
      .kpi-row { display: grid; grid-template-columns: repeat(4, 1fr); gap: 12px; margin-bottom: 1.5rem; }
      .kpi { background: #fff; border-radius: 10px; padding: 16px 18px; border: 1px solid #e8e6e0; box-shadow: 0 1px 3px rgba(0,0,0,0.05); }
      .kpi-label { font-size: 11px; color: #888; margin-bottom: 5px; font-weight: 500; }
      .kpi-val { font-size: 28px; font-weight: 700; line-height: 1; color: #8B0000; }
      .kpi-sub { font-size: 11px; color: #aaa; margin-top: 5px; }

      /* Grilles CSS responsives pour organiser les graphiques en colonnes */
      .g1 { display: grid; grid-template-columns: 1fr; gap: 16px; margin-bottom: 16px; }
      .g2 { display: grid; grid-template-columns: 1fr 1fr; gap: 16px; margin-bottom: 16px; }
      .g3 { display: grid; grid-template-columns: 1fr 1fr 1fr; gap: 16px; margin-bottom: 16px; }

      /* Style des conteneurs de graphiques (Tuiles blanches) */
      .card { background: #fff; border: 1px solid #e8e6e0; border-radius: 12px; padding: 18px 20px; box-shadow: 0 1px 3px rgba(0,0,0,0.05); display: flex; flex-direction: column; }
      .ctitle { font-size: 14px; font-weight: 600; color: #1a1a18; margin-bottom: 8px; border-left: 4px solid #8B0000; padding-left: 8px; }
      .cexp { font-size: 12px; color: #555; line-height: 1.6; margin-bottom: 14px; }
      .cexp strong { color: #8B0000; font-weight: 600; }

      /* Structure HTML/CSS personnalisée pour les barres de distribution de la population */
      .pop-grid { display: grid; grid-template-columns: repeat(3, 1fr); gap: 12px; margin-bottom: 16px; }
      .pop-item { background: #fff; border-radius: 10px; padding: 14px 16px; border: 1px solid #e8e6e0; }
      .pop-item-label { font-size: 11px; text-transform: uppercase; letter-spacing: 0.08em; color: #8B0000; margin-bottom: 10px; font-weight: 700; }
      .pop-bar-row { display: flex; align-items: center; gap: 8px; margin-bottom: 6px; }
      .pop-bar-label { font-size: 11px; color: #444; width: 130px; flex-shrink: 0; white-space: nowrap; overflow: hidden; text-overflow: ellipsis; }
      .pop-bar-track { flex: 1; background: #eee; border-radius: 3px; height: 8px; position: relative; }
      .pop-bar-fill { height: 8px; border-radius: 3px; }
      .pop-bar-pct { font-size: 11px; color: #444; font-weight: 600; width: 35px; text-align: right; flex-shrink: 0; }

    ")))
  ),

  # Contenu visible de la page
  tags$h1("Déterminants de l'absentéisme – EHIS 3 France"),
  uiOutput("subtitle_ui"), # Génère dynamiquement côté serveur
  uiOutput("kpis_ui"), # Génère dynamiquement

  # SECTION 1 : Description de la population
  tags$div(class = "block-title", "Description de la population analysée"),
  uiOutput("pop_grid_ui"),

  # SECTION 2 : Déterminant n°1 (Santé perçue)
  tags$div(class = "block-title", "Déterminant n°1 – La santé perçue"),
  tags$div(class = "g2",
    tags$div(class = "card",
      tags$div(class = "ctitle", "Composition absents / présents par niveau de santé perçue"),
      tags$div(class = "cexp", HTML("Graphique en <strong>barres empilées à 100 %</strong> montrant la part d'absents (bordeaux foncé) dans chaque groupe.")),
      plotlyOutput("c_sante", height = "240px")
    ),
    tags$div(class = "card",
      tags$div(class = "ctitle", "Durée moyenne d'absence (jours) selon la santé perçue"),
      tags$div(class = "cexp", HTML("La santé perçue influe aussi sur la <strong>durée</strong>. Plus la santé perçue se dégrade, plus les arrêts sont longs.")),
      plotlyOutput("c_sante_jours", height = "240px")
    )
  )
)
```

```

# SECTION 3 : Facteurs professionnels (CSP et effort au travail)
tags$div(class = "block-title", "Déterminants professionnels"),
tags$div(class = "g2",
  tags$div(class = "card",
    tags$div(class = "ctitle", "Taux d'absentéisme par CSP"),
    tags$div(class = "cexp", HTML("<strong>Taille de la bulle</strong> proportionnelle à l'effectif. Ligne pointillée = moyenne nationale.")),
    plotlyOutput("c_csp", height = "240px")
  ),
  tags$div(class = "card",
    tags$div(class = "ctitle", "Effort physique au travail"),
    tags$div(class = "cexp", HTML("<strong>Barres</strong> : taux d'absentéisme. <strong>Ligne</strong> : durée moyenne en jours.")),
    plotlyOutput("c_effort", height = "240px")
  )
),

# SECTION 4 : Genre et Âge (Dumbbell Chart)
tags$div(class = "block-title", "Déterminants démographiques"),
tags$div(class = "g1",
  tags$div(class = "card",
    tags$div(class = "ctitle", "Écart Femme / Homme par tranche d'âge"),
    tags$div(class = "cexp", HTML("<strong>Dumbbell chart</strong> mesurant l'écart relatif entre les genres (Point foncé = Femmes, Clair = Hommes).")),
    plotlyOutput("c_dumbbell", height = "180px")
  )
),

# SECTION 5 : Habitudes de vie (Tabac, IMC, Sport)
tags$div(class = "block-title", "Déterminants comportementaux de santé"),
tags$div(class = "g3",
  tags$div(class = "card",
    tags$div(class = "ctitle", "Statut tabagique"),
    plotlyOutput("c_tabac", height = "180px")
  ),
  tags$div(class = "card",
    tags$div(class = "ctitle", "IMC (Corpulence)"),
    plotlyOutput("c_imc", height = "180px")
  ),
  tags$div(class = "card",
    tags$div(class = "ctitle", "Fréquence de sport"),
    plotlyOutput("c_sport", height = "180px")
  )
),

# SECTION 6 : Parcours de soin et pathologies
tags$div(class = "block-title", "Recours aux soins et maladies"),
tags$div(class = "g2",
  tags$div(class = "card",
    tags$div(class = "ctitle", "Indicateurs de soins"),
    tags$div(class = "cexp", HTML("Plus la surface bordeaux s'étend vers l'extérieur, plus le taux d'absence lié est lourd.")),
    plotlyOutput("c_radar", height = "260px")
  ),
  tags$div(class = "card",
    tags$div(class = "ctitle", "Maladies chroniques"),
    tags$div(class = "cexp", HTML("Comparaison du taux d'absence chez les malades (bordeaux) vs non-malades (clair).")),
    plotlyOutput("c_maladies", height = "260px")
  )
),

# SECTION 7 : Distribution fine des arrêts
tags$div(class = "block-title", "Distribution des durées d'absence"),
tags$div(class = "g1",
  tags$div(class = "card",
    tags$div(class = "ctitle", "Répartition du nombre de jours d'absence"),
    plotlyOutput("c_dist", height = "220px")
  )
),
)
)

```

```

# =====
# 3. SERVER : CALCULS DYNAMIQUES ET LOGIQUE DE VISUALISATION (PLOTLY)
# =====

server <- function(input, output, session) {

  # FONCTION REUTILISABLE : Applique la charte graphique épurée
  apply_theme <- function(p, x_title = "", y_title = "") {
    p %>% layout(
      margin = list(t = 15, b = 35, l = 45, r = 25),
      paper_bgcolor = 'rgba(0,0,0,0)',
      plot_bgcolor = 'rgba(0,0,0,0)',
      font = list(family = "-apple-system, BlinkMacSystemFont, 'Segoe UI', sans-serif", size = 11, color = "#1a1a1a"),
      xaxis = list(title = x_title, gridcolor = "rgba(0,0,0,0.06)", zeroline = FALSE, tickfont = list(color = "#666666")),
      yaxis = list(title = y_title, gridcolor = "rgba(0,0,0,0.06)", zeroline = FALSE, tickfont = list(color = "#666666"))
    ) %>% config(displayModeBar = FALSE)
  }

  # RENDER: Texte dynamique d'en-tête
  output$subtitle_ui <- renderUI({
    tags$div(class = "subtitle",
      sprintf("Enquête européenne sur la santé - %s individus analysés · Population active en emploi",
        format(nrow(df), big.mark = " ")))
  })

  # RENDER: Création dynamique des 4 blocs de KPI du haut
  output$kpi5_ui <- renderUI({
    total_n <- nrow(df)
    abs_pct <- mean(df$sabsent_num, na.rm=TRUE) * 100
    abs_n <- sum(df$sabsent_num, na.rm=TRUE)
    avg_age <- mean(df$age_individu, na.rm=TRUE)
    med_days <- median(df$jours_absence_num[df$sabsent_num == 1], na.rm = TRUE)

    tags$div(class = "kpi-row",
      tags$div(class = "kpi", tags$div(class = "kpi-label", "Individus analysés"), tags$div(class = "kpi-val", format(total_n, big.mark = " ")), tags$div(class = "kpi-sub",
        tags$div(class = "kpi", tags$div(class = "kpi-label", "Taux d'absentéisme"), tags$div(class = "kpi-val", sprintf("%.1f %%", abs_pct)), tags$div(class = "kpi-sub", spr
        tags$div(class = "kpi", tags$div(class = "kpi-label", "Âge moyen"), tags$div(class = "kpi-val", sprintf("%.1f ans", avg_age)), tags$div(class = "kpi-sub", "Salariés a
        tags$div(class = "kpi", tags$div(class = "kpi-label", "Durée médiane d'absence"), tags$div(class = "kpi-val", sprintf("%g jours", med_days)), tags$div(class = "kpi-su
      )
    )
  })
}

```



```

# RENDER: Génération HTML/CSS pour les micro-barres de distribution
output$pop_grid_ui <- renderUI({
  build_section <- function(df_counts, label_col, colors) {
    df_pct <- df_counts %>% drop_na() %>% filter(![[label_col]] != "Inconnu", ![[label_col]] != "Non renseigné") %>% mutate(pct = round(n / sum(n) * 100))
    lapply(1:nrow(df_pct), function(i) {
      tags$div(class = "pop-bar-row",
        tags$span(class = "pop-bar-label", as.character(df_pct[i, label_col])),
        tags$div(class = "pop-bar-track",
          tags$div(class = "pop-bar-fill", style = sprintf("width:%d%%; background:%s;", df_pct$pct[i], colors[(i-1)%length(colors)+1]))
        ),
        tags$span(class = "pop-bar-pct", sprintf("%d%%", df_pct$pct[i]))
      )
    })
  }

  tags$div(class = "pop-grid",
    tags$div(class = "pop-item", tags$div(class = "pop-item-label", "Répartition par sexe"), build_section(df %>% count(sexe), "sexe", GRAD_2)),
    tags$div(class = "pop-item", tags$div(class = "pop-item-label", "Tranche d'âge"), build_section(df %>% count(tranche_age), "tranche_age", GRAD_3)),
    tags$div(class = "pop-item", tags$div(class = "pop-item-label", "Niveau d'éducation"), build_section(df %>% count(education), "education", GRAD_3)),
    tags$div(class = "pop-item", tags$div(class = "pop-item-label", "IMC (corpulence)"), build_section(df %>% count(imc_categorie), "imc_categorie", GRAD_5)),
    tags$div(class = "pop-item", tags$div(class = "pop-item-label", "Catégorie socio-pro"), build_section(df %>% count(csp_groupe), "csp_groupe", GRAD_5)),
    tags$div(class = "pop-item", tags$div(class = "pop-item-label", "Santé perçue"), build_section(df %>% count(sante_percue), "sante_percue", GRAD_3))
  )
})

# GRAPHIQUE 1 : Barres empilées 100% (Santé perçue vs statut d'absence)
output$sc_sante <- renderPlotly({
  df_sante <- df %>% drop_na(sante_percue) %>% group_by(sante_percue) %>%
    summarise(Absents = mean(absent_num)*100, Presents = 100 - (mean(absent_num)*100), .groups = "drop")

  plot_ly(df_sante, x = ~sante_percue, y = ~Absents, type = 'bar', name = 'Absents', marker = list(color = '#8B0000')) %>%
    add_bars(y = ~Presents, name = 'Présents', marker = list(color = '#E3ABAB')) %>%
    layout(barmode = 'stack', legend = list(orientation = 'h', y = 1.15), yaxiss = list(ticksuffix = "%")) %>%
    apply_theme()
})

# GRAPHIQUE 2 : Courbe d'évolution de la durée moyenne d'absence selon la santé perçue
output$sc_sante_jours <- renderPlotly({
  df_sante_j <- df %>% filter(absent_num == 1) %>% drop_na(sante_percue, jours_absence_num) %>% group_by(sante_percue) %>%
    summarise(Jours = mean(jours_absence_num, na.rm = TRUE), .groups = "drop")

  plot_ly(df_sante_j, x = ~sante_percue, y = ~Jours, type = 'scatter', mode = 'lines+markers',
    line = list(size = 3, width = 3), marker = list(color = '#8B0000', size = 8)) %>%
    layout(yaxis = list(title = "Jours d'absence")) %>% apply_theme()
})

# GRAPHIQUE 3 : Bubble Chart (CSP vs Absentéisme)
output$sc_csp <- renderPlotly({
  df_csp <- df %>% drop_na(csp_groupe) %>% group_by(csp_groupe) %>% summarise(Taux = mean(absent_num)*100, n = n(), .groups = "drop")
  avg_global <- mean(df$absent_num, na.rm=TRUE) * 100

  plot_ly(df_csp, x = ~Taux, y = ~reorder(csp_groupe, Taux), type = 'scatter', mode = 'markers',
    marker = list(size = ~n, sizemode = 'area', sizeref = max(df_csp$n)/1000, color = '#8B0000', opacity = 0.8)) %>%
    layout(xaxis = list(ticksuffix = "%"), yaxiss = list(title = ""))
    shapes = list(list(type = "line", x0 = avg_global, x1 = avg_global, y0 = 0, y1 = 1, yref = "paper",
      line = list(dash = "dash", color = "rgba(0,0,0,0.4)", width = 1.5))) %>% apply_theme()
})

# GRAPHIQUE 4 : Graphique combiné double-axe (Effort physique au travail)
output$sc_effort <- renderPlotly({
  df_effort_data <- df %>% filter(!is.na(effort_travail), effort_travail != "Non renseigné") %>% group_by(effort_travail) %>%
    summarise(Taux = mean(absent_num)*100, Jours = mean(jours_absence_num[absent_num == 1], na.rm = TRUE), .groups = "drop")

  plot_ly(df_effort_data) %>%
    add_bars(x = ~effort_travail, y = ~Taux, name = "Taux (%)", marker = list(color = '#8B0000')) %>%
    add_trace(x = ~effort_travail, y = ~Jours, name = "Jours", yaxiss = "y2", type = 'scatter', mode = 'lines+markers',
      line = list(color = '#4A0000', width = 2), marker = list(symbol = "triangle-up", size = 10, color = '#4A0000')) %>%
    layout(yaxis = list(title = "Taux (%)", ticksuffix = "%"),
      yaxiss2 = list(title = "Jours", overlying = "y", side = "right", showgrid = FALSE),
      legend = list(orientation = 'h', y = 1.15)) %>% apply_theme()
})

# GRAPHIQUE 5 : Dumbbell Chart (Écart Femme / Homme par tranche d'âge)
output$sc_dumbbell <- renderPlotly({
  df_db <- df %>% filter(sexe %in% c("Homme", "Femme")) %>% drop_na(tranche_age) %>% group_by(tranche_age, sexe) %>% summarise(Taux = mean(absent_num)*100, .groups = "drop") %>%
    pivot_wider(names_from = sexe, values_from = Taux)
  avg_global <- mean(df$absent_num, na.rm=TRUE) * 100

  plot_ly(df_db) %>%
    add_segments(x = ~Homme, xend = ~Femme, y = ~tranche_age, yend = ~tranche_age, line = list(color = "rgba(139,0,0,0.2)", width = 4), showlegend = FALSE) %>%
    add_markers(x = ~Homme, y = ~tranche_age, name = "Hommes", marker = list(color = '#E3ABAB', size = 11)) %>%
    add_markers(x = ~Femme, y = ~tranche_age, name = "Femmes", marker = list(color = '#8B0000', size = 11)) %>%
    layout(xaxis = list(ticksuffix = "%"), yaxiss = list(title = ""))
    shapes = list(list(type = "line", x0 = avg_global, x1 = avg_global, y0 = 0, y1 = 1, yref = "paper", line = list(dash = "dash", color = "rgba(0,0,0,0.3)", width = 1)))
})

# GRAPHIQUE 6 : Statut tabagique
output$sc_tabac <- renderPlotly({
  df_tabac <- df %>% drop_na(fumeur_statut) %>% group_by(fumeur_statut) %>% summarise(Taux = mean(absent_num)*100, .groups = "drop")
  plot_ly(df_tabac, x = ~fumeur_statut, y = ~Taux, type = 'bar', marker = list(color = '#8B0000')) %>%
    layout(yaxis = list(ticksuffix = "%")) %>% apply_theme()
})

# GRAPHIQUE 7 : Corpulence (IMC)
output$sc_imc <- renderPlotly({
  df_imc <- df %>% drop_na(imc_categorie) %>% filter(imc_categorie != "Inconnu") %>% group_by(imc_categorie) %>% summarise(Taux = mean(absent_num)*100, .groups = "drop")
  plot_ly(df_imc, x = ~imc_categorie, y = ~Taux, type = 'scatter', mode = 'lines+markers',
    line = list(color = '#8B0000', width = 2.5), marker = list(color = '#8B0000', size = 8),
    fill = 'tozeroy', fillcolor = 'rgba(139,0,0,0.1)') %>%
    layout(yaxis = list(ticksuffix = "%")) %>% apply_theme()
})

# GRAPHIQUE 8 : Fréquence de sport
output$sc_sport <- renderPlotly({
  df_sport <- df %>% drop_na(frequence_sport) %>% filter(frequence_sport != "Non renseigné") %>% group_by(frequence_sport) %>% summarise(Taux = mean(absent_num)*100, .groups = "drop")
  plot_ly(df_sport, x = ~frequence_sport, y = ~Taux, type = 'bar', marker = list(color = '#8B0000')) %>%
    layout(yaxis = list(ticksuffix = "%")) %>% apply_theme()
})

```

```

# GRAPHIQUE 9 : Radar (Recours aux soins)
output$sc_radar <- renderPlotly({
  vars <- c("hospitalisé", "prise_medicaments", "renoncement_soins", "consult_med_12_derniers_mois")
  labels <- c("Hospitalisé", "Médicaments", "Renoncement", "Consult. Méd.")
  vals <- sapply(vars, function(v) mean(df$absent_num[df[[v]] == "Oui"], na.rm=TRUE) * 100)
  avg_global <- mean(df$absent_num, na.rm=TRUE) * 100

  plot_ly(type = 'scatterpolar', mode = 'lines+markers') %>%
    add_trace(r = c(vals, vals[1]), theta = c(labels, labels[1]), name = "Taux catégorie",
              fill = 'toself', fillcolor = 'rgba(139,0,0,0.2)', line = list(color = '#8B0000', width = 2), marker = list(color = '#8B0000', size = 7)) %>%
    add_trace(r = rep(avg_global, 5), theta = c(labels, labels[1]), name = "Moyenne nat.",
              mode = 'lines', line = list(color = 'rgba(0,0,0,0.3)', dash = 'dash', width = 1.5)) %>%
    layout(polar = list(radialaxis = list(visible = TRUE, range = c(0, max(vals)+10), ticksuffix = "%")), legend = list(orientation = 'h', y = -0.15)) %>%
    apply_theme()
})

# GRAPHIQUE 10 : Maladies chroniques
output$sc_maladies <- renderPlotly({
  m_asthme <- df %>% drop_na(mal_asthme) %>% group_by(mal_asthme) %>% summarise(Taux = mean(absent_num)*100) %>% rename(Statut = mal_asthme) %>% mutate(Patho = "Asthme")
  m_dep <- df %>% drop_na(mal_depression) %>% group_by(mal_depression) %>% summarise(Taux = mean(absent_num)*100) %>% rename(Statut = mal_depression) %>% mutate(Patho = "Dépress")
  m_dos <- df %>% drop_na(mal_dos) %>% group_by(mal_dos) %>% summarise(Taux = mean(absent_num)*100) %>% rename(Statut = mal_dos) %>% mutate(Patho = "Mal de dos")
  df_m <- rbind(m_asthme, m_dep, m_dos)

  plot_ly(df_m, x = ~Patho, y = ~Taux, color = ~Statut, type = 'bar', colors = c("Non" = "#E3A8A8", "Oui" = "#8B0000")) %>%
    layout(barmode = 'group', yaxis = list(ticksuffix = "%"), legend = list(orientation = 'h', y = 1.15)) %>% apply_theme()
})

# GRAPHIQUE 11 : Histogramme des durées d'absence réelles
output$sc_dist <- renderPlotly({
  df_dist <- df %>% filter(absent_num == 1) %>% drop_na(jours_absence_num) %>% count(jours_absence_num) %>% mutate(Label = paste(jours_absence_num, "j"))

  plot_ly(df_dist, x = ~reorder(Label, jours_absence_num), y = ~n, type = 'bar', marker = list(color = '#8B0000')) %>%
    layout(xaxis = list(title = "Jours d'absence"), yaxis = list(title = "Effectif")) %>% apply_theme()
})
# =====
shinyApp(ui, server)

```

Code Regression logistique

```
# 1. Chargement des packages indispensables
library(sjPlot) # Pour créer la table finale des Odds Ratios avec tab_model()
library(ggplot2) # Pour concevoir le graphique
library(dplyr) # Pour manipuler et filtrer les données (filter, rename)
library(broom) # Pour extraire proprement les coefficients du modèle

# 2. Importation du jeu de données (séparateur virgule généré par write.csv)
data_reg <- read.csv("EHIS_Final_Propre.csv", sep = ",", stringsAsFactors = FALSE, encoding = "UTF-8")

# SECURITÉ AUTOMATIQUE : Gestion du séparateur si besoin
if (ncol(data_reg) == 1) {
  data_reg <- read.csv("EHIS_Final_Propre.csv", sep = ";", stringsAsFactors = FALSE, encoding = "UTF-8")
}

# =====
# 3. Préparation de TOUTES les variables qualitatives (Factor & Relevel)
# =====

# Variable cible : l'absentéisme (0 = Présent, 1 = Absent dans la version v8)
data_reg$est_absent <- factor(data_reg$est_absent)
data_reg$est_absent <- relevel(data_reg$est_absent, ref = "0")

# Caractéristiques démographiques et profil
data_reg$sexe <- factor(data_reg$sexe)
data_reg$sexe <- relevel(data_reg$sexe, ref = "Homme")

data_reg$tranche_age <- factor(data_reg$tranche_age)
data_reg$tranche_age <- relevel(data_reg$tranche_age, ref = ">50")

data_reg$imc_categorie <- factor(data_reg$imc_categorie)
data_reg$imc_categorie <- relevel(data_reg$imc_categorie, ref = "Normal") # Ajusté sur 'Normal'

data_reg$education <- factor(data_reg$education)
data_reg$education <- relevel(data_reg$education, ref = "Niveau brevet")

data_reg$csp_groupe <- factor(data_reg$csp_groupe)
data_reg$csp_groupe <- relevel(data_reg$csp_groupe, ref = "Cadres et professions intellectuelles")

# Santé perçue et Habitudes de vie
data_reg$sante_percue <- factor(data_reg$sante_percue)
data_reg$sante_percue <- relevel(data_reg$sante_percue, ref = "Bonne ou très bonne") # Ajusté sur 'Bonne ou très bonne'

data_reg$fumeur_statut <- factor(data_reg$fumeur_statut)
data_reg$fumeur_statut <- relevel(data_reg$fumeur_statut, ref = "Non-fumeur") # Ajusté sur 'Non-fumeur'

data_reg$alcool_frequence <- factor(data_reg$alcool_frequence)
data_reg$alcool_frequence <- relevel(data_reg$alcool_frequence, ref = "Jamais ou plus du tout")

# Conditions de travail et activité
data_reg$effort_travail <- factor(data_reg$effort_travail)
data_reg$effort_travail <- relevel(data_reg$effort_travail, ref = "Faible effort (Assis/Debout)")

data_reg$frequence_sport <- factor(data_reg$frequence_sport)
data_reg$frequence_sport <- relevel(data_reg$frequence_sport, ref = "Jamais")

# Recours aux soins
data_reg$consult_med_12_derniers_mois <- factor(data_reg$consult_med_12_derniers_mois)
data_reg$consult_med_12_derniers_mois <- relevel(data_reg$consult_med_12_derniers_mois, ref = "Non")

data_reg$hospitalise <- factor(data_reg$hospitalise)
data_reg$hospitalise <- relevel(data_reg$hospitalise, ref = "Non")

data_reg$prise_medicaments <- factor(data_reg$prise_medicaments)
data_reg$prise_medicaments <- relevel(data_reg$prise_medicaments, ref = "Non")

data_reg$renoncement_soins <- factor(data_reg$renoncement_soins)
data_reg$renoncement_soins <- relevel(data_reg$renoncement_soins, ref = "Non")

# Pathologies / Maladies
data_reg$mal_asthme <- factor(data_reg$mal_asthme)
data_reg$mal_asthme <- relevel(data_reg$mal_asthme, ref = "Non")

data_reg$mal_dos <- factor(data_reg$mal_dos)
data_reg$mal_dos <- relevel(data_reg$mal_dos, ref = "Non")
```

```

data_reg$mal_depression <- factor(data_reg$mal_depression)
data_reg$mal_depression <- relevel(data_reg$mal_depression, ref = "Non")

# =====
# 4. Construction du modèle de régression logistique globale
# =====
# Inclusion de l'ensemble des variables explicatives préparées
modele_logistique <- glm(
  est_absent ~ sexe + tranche_age + imc_categorie + education + csp_groupe +
    sante_percue + fumeur_statut + alcool_frequence + effort_travail +
    frequence_sport + consult_med_12_derniers_mois + hospitalise +
    prise_medicaments + renoncement_soins + mal_asthme + mal_dos + mal_depression,
  data = data_reg,
  family = binomial
)

# 5. Génération de la table HTML complète (Odds Ratios, IC 95% et P-values)
sjPlot::tab_model(modele_logistique)

# =====
# 6. Extraction et filtrage des résultats pour le graphique
# =====
resultats_coefficients <- broom::tidy(modele_logistique, exponentiate = TRUE, conf.int = TRUE) %>%
  dplyr::rename(
    Odds_Ratio = estimate, # Renomme l'estimation en Odds_Ratio
    IC_bas = conf.low,      # Borne inférieure de l'intervalle de confiance
    IC_haut = conf.high     # Borne supérieure de l'intervalle de confiance
  )

# 7. Génération du graphique des Odds Ratios Significatifs (p < 0.05)
graphique_or <- resultats_coefficients %>%
  dplyr::filter(term != "(Intercept)", p.value < 0.05) %>%
  ggplot(aes(x = reorder(term, Odds_Ratio), y = Odds_Ratio)) +
  geom_point(color = "#8B0000", size = 3) + # Harmonisé en bordeaux style Power BI
  geom_errorbar(aes(ymin = IC_bas, ymax = IC_haut), color = "#888888", width = 0.2) +
  geom_hline(yintercept = 1, linetype = "dashed", color = "#BA3C3C", size = 0.8) +
  coord_flip() +
  theme_minimal(base_family = "sans") +
  theme(
    plot.title = element_text(face = "bold", size = 13, color = "#8B0000"),
    plot.subtitle = element_text(size = 10, color = "#555555"),
    panel.grid.minor = element_blank(),
    panel.grid.major.x = element_line(color = "rgba(0,0,0,0.06)"),
    axis.text = element_text(size = 9, color = "#222222")
  ) +
  labs(
    title = "Facteurs d'influence significatifs sur l'absentéisme (Modèle Global)",
    subtitle = "Odds Ratios et intervalles de confiance à 95% (p < 0.05)",
    x = "Variables et modalités (comparées à leur référence)",
    y = "Odds Ratio (OR)"
  )

# 8. Affichage du graphique final dans RStudio
print(graphique_or)

```

Résultat de la régression logistique

est absent			
Predictors	Odds Ratios	CI	p
(Intercept)	0.12	0.09 – 0.16	<0.001
sexe [Femme]	1.21	1.08 – 1.37	0.002
tranche age [<30]	1.65	1.38 – 1.96	<0.001
tranche_age30-50	1.43	1.25 – 1.62	<0.001
imc categorie [Maigreur]	1.69	1.25 – 2.27	0.001
imc categorie [Obésité]	1.05	0.89 – 1.25	0.543
imc categorie [Surpoids]	1.13	1.00 – 1.28	0.057
education [Bac ou équivalent]	1.06	0.90 – 1.24	0.490
education [Études supérieures]	1.07	0.91 – 1.25	0.427
csp groupe [Employés et personnel de services]	1.18	1.00 – 1.40	0.053
csp groupe [Forces armées]	0.89	0.43 – 1.70	0.734
csp groupe [Ouvriers et métiers manuels]	1.14	0.94 – 1.37	0.182
csp groupe [Professions intermédiaires]	1.07	0.91 – 1.26	0.397

sante percue [Mauvaise ou très mauvaise]	4.11	3.05 – 5.58	<0.001
sante percue [Moyenne]	1.90	1.64 – 2.19	<0.001
fumeur statut [Occasionnel]	0.92	0.73 – 1.15	0.470
fumeur statut [Quotidien]	1.30	1.14 – 1.49	<0.001
alcool frequence [Au moins une fois par semaine]	0.96	0.82 – 1.12	0.610
alcool frequence [Occasionnel (Moins d'une fois par semaine)]	0.94	0.81 – 1.11	0.479
effort travail [Effort intense (Physique intense)]	1.21	1.02 – 1.44	0.029
effort travail [Effort modéré (Marche modéré)]	1.03	0.91 – 1.17	0.596
frequence sport [1 à 2 fois par semaine]	1.04	0.91 – 1.18	0.578
frequence sport [3 jours ou plus par semaine]	1.02	0.87 – 1.18	0.844
consult med 12 derniers mois [Oui]	1.16	1.04 – 1.30	0.010
hospitalise [Oui]	4.28	3.03 – 6.12	<0.001
prise medicaments [Oui]	1.99	1.77 – 2.24	<0.001
renoncement soins [Oui]	1.46	1.29 – 1.65	<0.001

mal asthme [Oui]	1.19	0.98 – 1.45	0.077
mal dos [Oui]	0.79	0.33 – 1.78	0.577
mal depression [Oui]	0.92	0.26 – 3.07	0.897
Observations	6902		